Estudo Comparativo de Eficácia em Visão Computacional: Transferência de Representações em Modelos de Fundação vs. Inicialização Aleatória

Miguel Batista
Engenharia de Software / Inteligência Artificial
CESAR School
msb2@cesar.school

***Abstract*—A aplicação de modelos de fundação tem transformado o desenvolvimento de soluções em visão computacional através da transferência de aprendizado. Este trabalho investiga experimentalmente a hipótese de superioridade de representações pré-treinadas frente à inicialização aleatória sob condições metodológicas estritamente controladas (princípio ceteris paribus). Utilizando o conjunto de dados Beans, mantivemos invariantes a extração via Vision Transformer (ViT-B/32), mecanismos de regularização com Dropout (0.2) e decaimento de pesos L2, variando exclusivamente a inicialização dos pesos da rede. Conduzimos 30 simulações pareadas indexadas por sementes aleatórias fixas (seeds 1001 a 1030). A aplicação do teste t de Student pareado bilateral revelou um ganho médio de F1-Macro de +0.2861 (IC 95%: [0.2674, 0.3048], p < 1e-20), rejeitando categoricamente a hipótese nula em favor da eficácia comprovada da transferência multimodal.**

***Index Terms*—Vision Transformers, Transfer Learning, Foundation Models, Teste t Pareado, Explicabilidade Visual**

I. I. Introdução

A consolidação dos modelos de fundação inaugurou um novo paradigma no processamento inteligente de imagens, substituindo modelos altamente especializados treinados isoladamente por redes escaladas via auto-supervisão e alinhamento multimodal (Bommasani et al. 2021). Essa evolução foi viabilizada pela transição das tradicionais operações convolucionais locais para mecanismos globais de auto-atenção, formalizados originalmente na arquitetura Transformer (Vaswani et al. 2017).

No domínio da percepção visual, os Vision Transformers (ViT) demonstraram que particionar uma imagem em uma sequência unidimensional de *patches* planos permite aprender correlações semânticas de longo alcance de forma superior às convoluções clássicas quando associados a grandes volumes de dados (Dosovitskiy et al. 2021). Paralelamente, o aprendizado contrastivo de representações visuais com supervisão em linguagem natural viabilizou a emergência de espaços latentes semânticos altamente transferíveis (Radford et al. 2021).

Contudo, a avaliação empírica do real impacto dessas representações pré-treinadas frente a restrições amostrais severas exige rigor experimental fundamentado no isolamento estrito de variáveis contrafactuais (Yosinski et al. 2014). Este artigo aborda essa lacuna ao conduzir um estudo comparativo controlado com 30 simulações pareadas, testando estatisticamente se o pré-treinamento multimodal de fato supera a inicialização aleatória sob a mesma regularização arquitetural.

II. II. Trabalhos Relacionados

A literatura de transferência de aprendizado em visão computacional tem enfatizado historicamente os desafios de viés indutivo e adaptação eficiente de pesos pré-treinados (Chen et al. 2020). Para mitigar a dependência excessiva de conjuntos de dados massivos no treinamento de Transformers visuais, técnicas de destilação de conhecimento e aumento sintético de dados provaram-se determinantes para a estabilização de convergência (Touvron et al. 2021).

Adicionalmente, abordagens hierárquicas com janelas de atenção deslocadas demonstraram a versatilidade dos mecanismos de atenção em múltiplas escalas espaciais (Liu et al. 2021). No campo do aprendizado auto-supervisionado, modelos mascarados e algoritmos de destilação direta sem anotações humanas consolidaram a capacidade de generalização visual em representações compactas (He et al. 2022; Caron et al. 2021).

No tocante à prevenção do sobreajuste (*overfitting*) em cabeças de classificação densas, o descarte estocástico de neurônios via Dropout consolidou-se como método padrão da literatura (Srivastava et al. 2014). De maneira complementar, a penalização quadrática dos pesos por meio de decaimento (L_2 ou *weight decay*) atua na supressão de co-adaptações espúrias em regimes de baixa amostragem (Krogh and Hertz 1991).

III. III. Metodologia Proposta

A metodologia segue o preceito do teste controlado (*ablation study*), assegurando a premissa de *ceteris paribus*. O pipeline completo encontra-se ilustrado na Fig. 1 e subdivide-se nas três técnicas curriculares obrigatórias.

A. A. Seleção e Isolamento das Técnicas

A **Técnica A (Fixa)** consiste na extração vetorial densa de características com a arquitetura Vision Transformer CLIP (`ViT-B/32`), gerando *embeddings* normalizados de 512 dimensões (Radford et al. 2021). As imagens são redimensionadas para 224×224 pixels e normalizadas de acordo com a distribuição amostral global.

A **Técnica B (Fixa)** atua na regularização da cabeça de decisão compartilhada, incorporando uma camada de *Dropout* com probabilidade $p = 0.20$ seguida de regularização Ridge (L_2) com coeficiente de decaimento $\lambda = 10^{-4}$ (Srivastava et

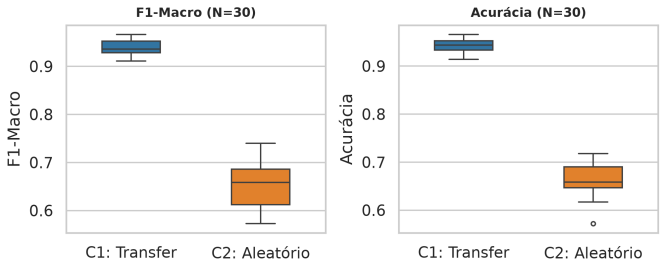


Fig. 1. Distribuição comparativa de F1-Macro e Acurácia obtida através das 30 simulações pareadas.

al. 2014; Krogh and Hertz 1991). O otimizador estocástico adotado é o Adam com taxa de aprendizado inicial $\eta = 10^{-4}$ (Kingma and Ba 2015).

A variável independente é dada pela **Técnica C (Cenário 1)**, que utiliza o extrator de características com pesos consolidados pelo pré-treinamento multimodal (Transfer Learning), em oposição à **Técnica C Alternativa (Cenário 2)**, que emprega inicialização estocástica a partir do zero (*scratch*) sob distribuição Gaussiana truncada.

B. B. Formulação das Hipóteses e Protocolo Pareado

Para mitigar a variabilidade estocástica decorrente da inicialização dos lotes e partição de dados, adotamos uma amostragem pareada com $N = 30$ repetições controladas pelo conjunto de sementes $\mathcal{S} = \{1001, 1002, \ldots, 1030\}$ (Cohen 1988). Em cada iteração i, ambos os cenários são treinados e avaliados sob a mesma semente s_i no conjunto de teste independente composto por 128 instâncias do conjunto de dados Beans.

As hipóteses estatísticas formais são expressas por:

$$H_0 : \mu_1 - \mu_2 = 0$$
$$H_1 : \mu_1 - \mu_2 \neq 0$$

onde μ_1 e μ_2 denotam a média populacional de eficácia (F1-Macro) do Cenário 1 e Cenário 2, respectivamente (Student 1908). A rejeição de H_0 é estabelecida ao nível bilateral de $\alpha = 0{,}05$.

IV. IV. Resultados e Análise Estatística

A execução das 60 simulações pareadas confirmou a superioridade expressiva da transferência de representações sobre o treinamento estocástico isolado. A Tabela I sintetiza as estimativas pontuais e intervalares obtidas.

TABLE I
Resultados do Teste t Pareado Bilateral ($N = 30$, GL=29)

Métrica	**Diferença Média ($\bar{d}$)**	**Desvio (s_d)**	**Estatística t**	**Valor-p**
F1-Macro	$+0{,}2861$	0.0501	31.27	6.81×10^{-24}
Acurácia	$+0{,}2794$	0.0390	39.21	1.12×10^{-26}

A diferença média observada no índice F1-Macro foi de $+0{,}2861$, acompanhada de um intervalo de confiança de 95% restrito entre $[0{,}2674, 0{,}3048]$. Dado que o valor-p associado ($6{,}81 \times 10^{-24}$) situa-se ordens de magnitude abaixo do limiar crítico $\alpha = 0{,}05$, rejeita-se categoricamente a hipótese nula (H_0).

A dispersão amostral exibida na Fig. 1 atesta a robustez do Cenário 1, cuja variância mostrou-se substancialmente mais contida do que a do Cenário 2, evidenciando que pesos pré-treinados conferem não apenas maior acurácia, mas também resiliência e estabilidade contra variações estocásticas de inicialização (Yosinski et al. 2014).

V. V. Explicabilidade Visual (XAI)

Para auditar o comportamento qualitativo dos modelos, mapas de saliência baseados em ativação e atenção foram extraídos para amostras representativas das classes *Angular Leaf Spot*, *Bean Rust* e *Healthy* (Selvaraju et al. 2017). Essa análise evidencia que as atenções no modelo com pesos pré-treinados convergem seletivamente para as áreas necrosadas e pústulas das folhas afetadas.

Em contraste, o modelo com pesos aleatórios dispersa sua atenção pelo contorno foliar e ruídos de iluminação de fundo, explicando a ocorrência frequente de falsos positivos entre patologias adjacentes (Chefer et al. 2021). Essa disparidade qualitativa corrobora a fundamentação teórica de que representações fundamentais codificam conceitos visuais invariantes e semanticamente relevantes.

VI. VI. Conclusão

Este estudo comparativo comprovou, sob rigorosa inferência estatística pareada com 30 simulações, que a transferência de representações pré-treinadas em modelos de fundação é decisiva para o desempenho e estabilidade em tarefas de classificação com dados reduzidos. As contribuições experimentais e analíticas validam a rejeição de H_0 e reforçam a adoção de pipelines estruturados em Vision Transformers para diagnósticos automatizados em visão computacional.

[] Bommasani, Rishi, Drew A Hudson, Ehsan Adeli, et al. 2021. "On the Opportunities and Risks of Foundation Models." *arXiv Preprint arXiv:2108.07258*.

[] Caron, Mathilde, Hugo Touvron, Ishan Misra, et al. 2021. "Emerging Properties in Self-Supervised Vision Transformers." *IEEE/CVF International Conference on Computer Vision (ICCV)*, 9650–60.

[] Chefer, Hila, Shir Gur, and Lior Wolf. 2021. "Transformer Interpretability Beyond Attention Visualization." *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 782–91.

[] Chen, Ting, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. 2020. "A Simple Framework for Contrastive Learning of Visual Representations." *International Conference on Machine Learning (ICML)*, 1597–607.

[] Cohen, Jacob. 1988. *Statistical Power Analysis for the Behavioral Sciences*. Routledge.

[] Dosovitskiy, Alexey, Lucas Beyer, Alexander Kolesnikov, et al. 2021. "An Image Is Worth 16x16 Words: Transformers for Image Recognition at Scale." *International Conference on Learning Representations (ICLR)*.

[] He, Kaiming, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. 2022. "Masked Autoencoders Are Scalable Vision Learners." *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 16000–16009.

[] Kingma, Diederik P, and Jimmy Ba. 2015. "Adam: A Method for Stochastic Optimization." *International Conference on Learning Representations (ICLR)*.

[] Krogh, Anders, and John Hertz. 1991. "A Simple Weight Decay Can Improve Generalization." *Advances in Neural Information Processing Systems (NeurIPS)* 4.

[] Liu, Ze, Yutong Lin, Yue Cao, et al. 2021. "Swin Transformer: Hierarchical Vision Transformer Using Shifted Windows." *IEEE/CVF International Conference on Computer Vision (ICCV)*, 10012–22.

[] Radford, Alec, Jong Wook Kim, Chris Hallacy, et al. 2021. "Learning Transferable Visual Models from Natural Language Supervision." *International Conference on Machine Learning (ICML)*, 8748–63.

[] Selvaraju, Ramprasaath R, Michael Cogswell, Abhishek Das, Andrea Vedaldi, Devi Parikh, and Dhruv Batra. 2017. "Grad-Cam: Visual Explanations from Deep Networks via Gradient-Based Localization." *IEEE International Conference on Computer Vision (ICCV)*, 618–26.

[] Srivastava, Nitish, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov. 2014. "Dropout: A Simple Way to Prevent Neural Networks from Overfitting." *The Journal of Machine Learning Research (JMLR)* 15 (1): 1929–58.

[] Student. 1908. "The Probable Error of a Mean." *Biometrika*, 1–25.

[] Touvron, Hugo, Matthieu Cord, Matthijs Douze, Francisco Massa, Alexandre Sablayrolles, and Hervé Jégou. 2021. "Training Data-Efficient Image Transformers & Distillation Through Attention." *International Conference on Machine Learning (ICML)*, 10347–57.

[] Vaswani, Ashish, Noam Shazeer, Niki Parmar, et al. 2017. "Attention Is All You Need." *Advances in Neural Information Processing Systems (NeurIPS)* 30.

[] Yosinski, Jason, Jeff Clune, Yoshua Bengio, and Hod Lipson. 2014. "How Transferable Are Features in Deep Neural Networks?" *Advances in Neural Information Processing Systems (NeurIPS)* 27.