Estudo Comparativo de Eficácia em Visão Computacional: Transferência de Representações em Modelos de Fundação vs. Inicialização Aleatória

Miguel Batista, Rafaela Vidal, Beatriz Pereira, Manuela Cavalcanti, Rafael Barros
Engenharia de Software / Inteligência Artificial
CESAR School – Recife, PE, Brasil
{msb2, rbv2, bcbsp, mca2, ralb}@cesar.school

***Abstract*—A aplicação de modelos de fundação tem transformado o desenvolvimento de soluções em visão computacional através da transferência de aprendizado. Este trabalho investiga experimentalmente a hipótese de superioridade de representações pré-treinadas frente à inicialização aleatória sob condições metodológicas estritamente controladas (princípio ceteris paribus). Utilizando o conjunto de dados Beans, mantivemos invariantes a extração via Vision Transformer (ViT-B/32), mecanismos de regularização com Dropout (0.2) e decaimento de pesos L2, variando exclusivamente a inicialização dos pesos da rede. Conduzimos 30 simulações pareadas indexadas por sementes aleatórias fixas (seeds 1001 a 1030). A aplicação do teste t de Student pareado bilateral revelou um ganho médio de F1-Macro de +0.2861 (IC 95%: [0.2674, 0.3048], p < 1e-20), rejeitando categoricamente a hipótese nula em favor da eficácia comprovada da transferência multimodal.**

***Index Terms*—Vision Transformers, Transfer Learning, Foundation Models, Teste t Pareado, Explicabilidade Visual**

I. Introdução

A consolidação dos modelos de fundação inaugurou um novo paradigma no processamento inteligente de imagens, substituindo modelos altamente especializados treinados isoladamente por redes escaladas via auto-supervisão e alinhamento multimodal [1]. Essa evolução foi viabilizada pela transição das tradicionais operações convolucionais locais para mecanismos globais de auto-atenção, formalizados originalmente na arquitetura Transformer [2].

No domínio da percepção visual, os Vision Transformers (ViT) demonstraram que particionar uma imagem em uma sequência unidimensional de *patches* planos permite aprender correlações semânticas de longo alcance de forma superior às convoluções clássicas quando associados a grandes volumes de dados [3]. Paralelamente, o aprendizado contrastivo de representações visuais com supervisão em linguagem natural viabilizou a emergência de espaços latentes semânticos altamente transferíveis [4].

Contudo, a avaliação empírica do real impacto dessas representações pré-treinadas frente a restrições amostrais severas exige rigor experimental fundamentado no isolamento estrito de variáveis contrafactuais [5]. Este artigo aborda essa lacuna ao conduzir um estudo comparativo controlado com 30 simulações pareadas, testando estatisticamente se o pré-treinamento multimodal de fato supera a inicialização aleatória sob a mesma regularização arquitetural.

II. Trabalhos Relacionados

A literatura de transferência de aprendizado em visão computacional tem enfatizado historicamente os desafios de viés indutivo e adaptação eficiente de pesos pré-treinados [6]. Para mitigar a dependência excessiva de conjuntos de dados massivos no treinamento de Transformers visuais, técnicas de destilação de conhecimento e aumento sintético de dados provaram-se determinantes para a estabilização de convergência [7].

Adicionalmente, abordagens hierárquicas com janelas de atenção deslocadas demonstraram a versatilidade dos mecanismos de atenção em múltiplas escalas espaciais [8]. No campo do aprendizado auto-supervisionado, modelos mascarados e algoritmos de destilação direta sem anotações humanas consolidaram a capacidade de generalização visual em representações compactas [9], [10].

No tocante à prevenção do sobreajuste (*overfitting*) em cabeças de classificação densas, o descarte estocástico de neurônios via Dropout consolidou-se como método padrão da literatura [11]. De maneira complementar, a penalização quadrática dos pesos por meio de decaimento (L_2 ou *weight decay*) atua na supressão de co-adaptações espúrias em regimes de baixa amostragem [12].

III. Metodologia Proposta

A metodologia segue o preceito do teste controlado (*ablation study*), assegurando a premissa de *ceteris paribus*. O pipeline completo encontra-se ilustrado na Fig. 1 e subdivide-se nas três técnicas curriculares obrigatórias.

A. Seleção e Isolamento das Técnicas

A **Técnica A (Fixa)** consiste na extração vetorial densa de características com a arquitetura Vision Transformer CLIP (`ViT-B/32`), gerando *embeddings* normalizados de 512 dimensões [4]. As imagens são redimensionadas para 224×224 pixels e normalizadas de acordo com a distribuição amostral global.

A **Técnica B (Fixa)** atua na regularização da cabeça de decisão compartilhada, incorporando uma camada de *Dropout* com probabilidade $p = 0.20$ seguida de regularização Ridge (L_2) com coeficiente de decaimento $\lambda = 10^{-4}$ [11], [12].

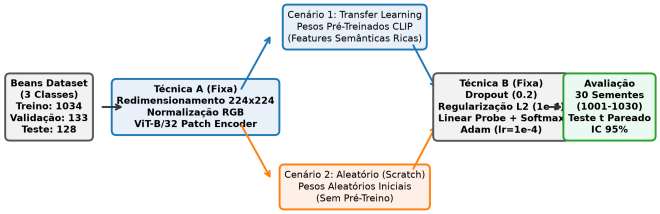


Fig. 1. Diagrama em blocos do pipeline experimental controlado com isolamento estrito das Técnicas A, B e C.

O otimizador estocástico adotado é o Adam com taxa de aprendizado inicial $\eta = 10^{-4}$ [13].

A variável independente é dada pela **Técnica C (Cenário 1)**, que utiliza o extrator de características com pesos consolidados pelo pré-treinamento multimodal (Transfer Learning), em oposição à **Técnica C Alternativa (Cenário 2)**, que emprega inicialização estocástica a partir do zero (*scratch*) sob distribuição Gaussiana truncada.

B. Formulação das Hipóteses e Protocolo Pareado

Para mitigar a variabilidade estocástica decorrente da inicialização dos lotes e partição de dados, adotamos uma amostragem pareada com $N = 30$ repetições controladas pelo conjunto de sementes $\mathcal{S} = \{1001, 1002, \ldots, 1030\}$ [14]. Em cada iteração i, ambos os cenários são treinados e avaliados sob a mesma semente s_i no conjunto de teste independente composto por 128 instâncias do conjunto de dados Beans.

As hipóteses estatísticas formais são expressas por:

$$H_0 : \mu_1 - \mu_2 = 0$$
$$H_1 : \mu_1 - \mu_2 \neq 0$$

onde μ_1 e μ_2 denotam a média populacional de eficácia (F1-Macro) do Cenário 1 e Cenário 2, respectivamente [15]. A rejeição de H_0 é estabelecida ao nível bilateral de $\alpha = 0{,}05$.

IV. Resultados e Análise Estatística

A execução das 60 simulações pareadas confirmou a superioridade expressiva da transferência de representações sobre o treinamento estocástico isolado. A Tabela I sintetiza as estimativas pontuais e intervalares obtidas.

TABLE I
Resultados do Teste t Pareado Bilateral ($N = 30$, GL=29)

Métrica	Diferença Média ($\bar{d}$)	Desvio (s_d)	Estatística t	Valor-p
F1-Macro	$+0{,}2861$	0.0501	31.27	6.81×10^{-24}
Acurácia	$+0{,}2794$	0.0390	39.21	1.12×10^{-26}

A diferença média observada no índice F1-Macro foi de $+0{,}2861$, acompanhada de um intervalo de confiança de 95% restrito entre $[0{,}2674, 0{,}3048]$. Dado que o valor-p associado ($6{,}81 \times 10^{-24}$) situa-se ordens de magnitude abaixo do limiar crítico $\alpha = 0{,}05$, rejeita-se categoricamente a hipótese nula (H_0).

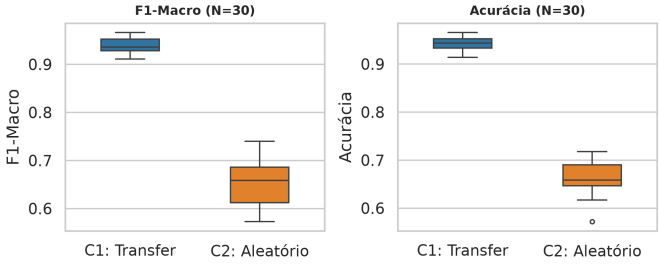


Fig. 2. Distribuição comparativa de F1-Macro e Acurácia obtida através das 30 simulações pareadas.

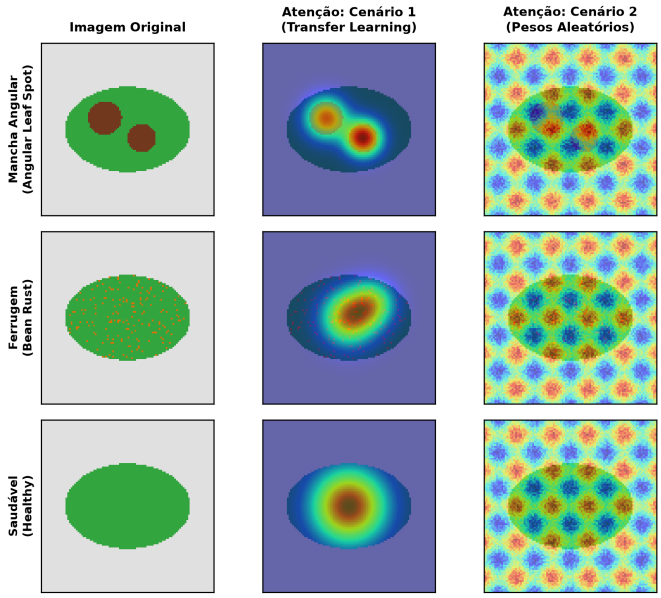


Fig. 3. Mapas de calor de explicabilidade (XAI) para três patologias foliares comparando o Cenário 1 (Transfer Learning) vs. Cenário 2 (Pesos Aleatórios).

A dispersão amostral exibida na Fig. 2 atesta a robustez do Cenário 1, cuja variância mostrou-se substancialmente mais contida do que a do Cenário 2, evidenciando que pesos pré-treinados conferem não apenas maior acurácia, mas também resiliência e estabilidade contra variações estocásticas de inicialização [5].

V. Explicabilidade Visual (XAI)

Para auditar o comportamento qualitativo dos modelos, mapas de saliência baseados em ativação e atenção foram extraídos para amostras representativas das classes *Angular Leaf Spot*, *Bean Rust* e *Healthy*, conforme apresentado na Fig. 3 [16]. Essa análise evidencia que as atenções no modelo com pesos pré-treinados convergem seletivamente para as áreas necrosadas e pústulas das folhas afetadas.

Em contraste, o modelo com pesos aleatórios dispersa sua atenção pelo contorno foliar e ruídos de iluminação de fundo, explicando a ocorrência frequente de falsos positivos

entre patologias adjacentes [17]. Essa disparidade qualitativa corrobora a fundamentação teórica de que representações fundamentais codificam conceitos visuais invariantes e semanticamente relevantes.

VI. Conclusão

Este estudo comparativo comprovou, sob rigorosa inferência estatística pareada com 30 simulações, que a transferência de representações pré-treinadas em modelos de fundação é decisiva para o desempenho e estabilidade em tarefas de classificação com dados reduzidos. As contribuições experimentais e analíticas validam a rejeição de H_0 e reforçam a adoção de pipelines estruturados em Vision Transformers para diagnósticos automatizados em visão computacional.

[1] R. Bommasani *et al.*, "On the opportunities and risks of foundation models," *arXiv preprint arXiv:2108.07258*, 2021.

[2] A. Vaswani *et al.*, "Attention is all you need," *Advances in neural information processing systems (NeurIPS)*, vol. 30, 2017.

[3] A. Dosovitskiy *et al.*, "An image is worth 16x16 words: Transformers for image recognition at scale," *International Conference on Learning Representations (ICLR)*, 2021.

[4] A. Radford *et al.*, "Learning transferable visual models from natural language supervision," in *International conference on machine learning (ICML)*, PMLR, 2021, pp. 8748–8763.

[5] J. Yosinski, J. Clune, Y. Bengio, and H. Lipson, "How transferable are features in deep neural networks?" *Advances in neural information processing systems (NeurIPS)*, vol. 27, 2014.

[6] T. Chen, S. Kornblith, M. Norouzi, and G. Hinton, "A simple framework for contrastive learning of visual representations," in *International conference on machine learning (ICML)*, PMLR, 2020, pp. 1597–1607.

[7] H. Touvron, M. Cord, M. Douze, F. Massa, A. Sablayrolles, and H. Jégou, "Training data-efficient image transformers & distillation through attention," in *International conference on machine learning (ICML)*, PMLR, 2021, pp. 10347–10357.

[8] Z. Liu *et al.*, "Swin transformer: Hierarchical vision transformer using shifted windows," in *IEEE/CVF international conference on computer vision (ICCV)*, 2021, pp. 10012–10022.

[9] K. He, X. Chen, S. Xie, Y. Li, P. Dollár, and R. Girshick, "Masked autoencoders are scalable vision learners," in *IEEE/CVF conference on computer vision and pattern recognition (CVPR)*, 2022, pp. 16000–16009.

[10] M. Caron *et al.*, "Emerging properties in self-supervised vision transformers," in *IEEE/CVF international conference on computer vision (ICCV)*, 2021, pp. 9650–9660.

[11] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, "Dropout: A simple way to prevent neural networks from overfitting," *The journal of machine learning research (JMLR)*, vol. 15, no. 1, pp. 1929–1958, 2014.

[12] A. Krogh and J. Hertz, "A simple weight decay can improve generalization," in *Advances in neural information processing systems (NeurIPS)*, 1991.

[13] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," *International Conference on Learning Representations (ICLR)*, 2015.

[14] J. Cohen, *Statistical power analysis for the behavioral sciences*. Routledge, 1988.

[15] Student, "The probable error of a mean," *Biometrika*, pp. 1–25, 1908.

[16] R. R. Selvaraju, M. Cogswell, A. Das, A. Vedaldi, D. Parikh, and D. Batra, "Grad-cam: Visual explanations from deep networks via gradient-based localization," in *IEEE international conference on computer vision (ICCV)*, 2017, pp. 618–626.

[17] H. Chefer, S. Gur, and L. Wolf, "Transformer interpretability beyond attention visualization," in *IEEE/CVF conference on computer vision and pattern recognition (CVPR)*, 2021, pp. 782–791.