Estudo Comparativo de Otimização em Redes Neurais Convolucionais para Diagnóstico de Pneumonia: Transferência de Aprendizado vs. Treinamento do Zero

Miguel Batista, Rafaela Vidal, Beatriz Pereira, Manuela Cavalcanti, Rafael Barros
Engenharia de Software / Inteligência Artificial
CESAR School – Recife, PE, Brasil
{msb2, rbv2, bcbsp, mca2, ralb}@cesar.school

***Abstract*—O diagnóstico assistido por computador em radiografias de tórax demanda modelos de alta acurácia com garantias de interpretabilidade clínica. Este artigo conduz uma investigação empírica rigorosa sobre a eficácia da transferência de aprendizado (*Transfer Learning*) frente ao treinamento a partir do zero (*Scratch*) sob um agendamento com aquecimento linear e decaimento cosseno (*Linear Warmup with Cosine Annealing*), isolando estritamente a variável independente sob o princípio *ceteris paribus*. O pipeline integra Data Augmentation estocástico (Técnica A), arquitetura profunda ResNet-50 com explicabilidade visual Grad-CAM e auditoria clínica via modelo multimodal LMM (Técnica B), variando unicamente o protocolo de inicialização e otimização dos pesos da rede (Técnica C). Foram executadas 30 simulações pareadas indexadas pelas sementes aleatórias 1001 a 1030 (60 treinamentos completos) em 582 radiografias de teste independentes. O teste t de Student pareado bilateral revelou um ganho estatisticamente significativo de F1-Macro de +0.0997 (IC 95%: [0.0794, 0.1199], t = 10.07, p = 5.63e-11) e acurácia de +0.0918 (p = 1.03e-09), refutando a hipótese nula. A explicabilidade visual validada pelo LMM confirmou que a convergência com pesos pré-treinados ancora a atenção no parênquima pulmonar patológico, suprimindo ativações espúrias em estruturas ósseas.**

***Index Terms*—Radiografia de Tórax, Pneumonia, ResNet-50, Transfer Learning, Grad-CAM, Teste t Pareado**

I. Introdução

A pneumonia representa uma das principais causas infecciosas de hospitalização e mortalidade global, exigindo triagem diagnóstica precisa através de radiografias de tórax (*Chest X-Ray*) [1]. A automatização desse processo por meio de redes neurais convolucionais profundas (CNNs) tem demonstrado alta eficácia na detecção de consolidações e infiltrados alveolares [2]. Contudo, a generalização desses modelos depende criticamente da qualidade das representações visuais aprendidas sob restrições de amostragem clínica e assimetria de classes [3].

No paradigma clássico de aprendizado supervisionado, a transferência de conhecimento oriunda de bases massivas de imagens naturais (como o ImageNet-1k) viabiliza a extração de filtros espaciais fundamentais (bordas, texturas e contornos) capazes de acelerar a convergência e atenuar o sobreajuste (*overfitting*) [4]. Em contrapartida, avanços recentes em políticas de agendamento de taxa de aprendizado — notadamente o aquecimento linear seguido de decaimento por cosseno (*Warmup with Cosine Annealing*) — argumentam que o treinamento a partir do zero pode, sob determinadas condições, atingir desempenho competitivo e reduzir vieses específicos de domínios externos [5], [6].

Nesse cenário, torna-se imperativo discernir causalmente se a superioridade frequentemente atribuída ao *Transfer Learning* reflete uma vantagem estatisticamente robusta ou apenas variações estocásticas de inicialização [7]. Este artigo aborda essa lacuna conduzindo um estudo comparativo controlado com 30 simulações pareadas ($N = 30$), submetidas ao Teste t de Student pareado, integrando explicabilidade por Grad-CAM e laudos diagnósticos automatizados por Modelos de Linguagem e Visão Multimodais (LMM).

II. Fundamentação Teórica

A literatura médica e de visão computacional consolidou as redes residuais profundas (*Residual Networks* - ResNet) como o padrão ouro para análise de padrões patológicos complexos [4]. A incorporação de conexões de salto (*skip connections*) mitiga o problema da dissipação de gradientes, viabilizando o fluxo de sinal através de dezenas de camadas convolucionais hierárquicas [8].

Para assegurar a robustez contra variações anatômicas e de scanner radiológico, o aumento estocástico de dados (*Data Augmentation*) atua como regularizador implícito fundamental, simulando variações de orientação e contraste [9]. De maneira complementar, o método Grad-CAM (*Gradient-weighted Class Activation Mapping*) calcula a contribuição dos gradientes da classe patológica em relação aos mapas de ativação da última camada convolucional, produzindo mapas de calor 2D que indicam a localização espacial dos achados radiológicos [10].

Recentemente, a integração de modelos multimodais de fundação (LMMs) tem emergido como mecanismo avançado para auditar a coerência clínica dos mapas de calor de redes profundas, transcrevendo atenções visuais em laudos diagnósticos estruturados em linguagem natural [11], [12].

III. Metodologia Proposta

A metodologia experimental foi desenhada em estrita conformidade com o princípio de *ceteris paribus*, isolando a estratégia de otimização e inicialização dos pesos como a única variável independente. A Fig. 1 ilustra as instâncias radiológicas avaliadas.

A. Seleção e Isolamento das Técnicas

A esteira de processamento organiza-se nas três técnicas curriculares:

1. **Técnica A (Fixa / Pré-processamento):** *Data Augmentation* estocástico composto por redimensionamento para 224×224 pixels, espelhamento horizontal estocástico ($p = 0.50$), rotação aleatória de $\pm 10^{\circ}$ e perturbação dinâmica de brilho e contraste ($\pm 10\%$). A semente estocástica s_i governa deterministicamente essas transformações em cada rodada.
2. **Técnica B (Fixa / Arquitetura e Explicabilidade):** Classificador convolucional profundo baseado na arquitetura ResNet-50 com *Bottleneck Residual Blocks*, acoplado ao extrator de Grad-CAM sobre a camada `layer4` e ao serviço local de laudo multimodal (LMM) via interface OpenAI-compatible (`localhost:8080`).
3. **Técnica C (Variável Independente):**
   - *Cenário 1 (Transfer Learning):* ResNet-50 inicializada com pesos pré-treinados na base ImageNet-1k, otimizada via Adam ($\eta = 10^{-4}$, decaimento $L_2 = 10^{-4}$).
   - *Cenário 2 (Scratch / Contrafactual):* ResNet-50 inicializada pelo método He Normal [13], submetida a 1 época de *Linear Warmup* seguida por decaimento suave de cosseno (*Cosine Annealing*) com taxa de aprendizado $\eta_{\max} = 3 \times 10^{-4}$ e $\eta_{\min} = 10^{-6}$.

B. Protocolo Experimental Pareado ($N = 30$)

A base de dados totaliza 4.659 radiografias de tórax pediátricas reais [1]. A partição de treino congrega 4.077 imagens (1.104 controles sadios e 2.973 com pneumonia patológica). Para garantir inferência estatística sem viés de partição, fixamos o conjunto de teste em 582 radiografias reais (171 sadias e 411 com pneumonia), mantido estritamente imutável durante as 60 execuções. A amostragem pareada percorre as sementes inteiras $\mathcal{S} = \{1001, 1002, \ldots, 1030\}$ [14].

Em cada simulação pareada i, ambos os cenários são submetidos à exata mesma sequência de lotes de treino ($batch = 64$) acelerada nativamente por hardware GPU dedicado. As hipóteses estatísticas bilaterais formulam-se como:

$$H_0 : \mu_1 - \mu_2 = 0$$
$$H_1 : \mu_1 - \mu_2 \neq 0$$

onde μ_1 e μ_2 representam a média populacional de eficácia (F1-Macro e Acurácia) do Cenário 1 e Cenário 2, respectivamente [15]. Adota-se o nível crítico bilateral de $\alpha = 0{,}05$.

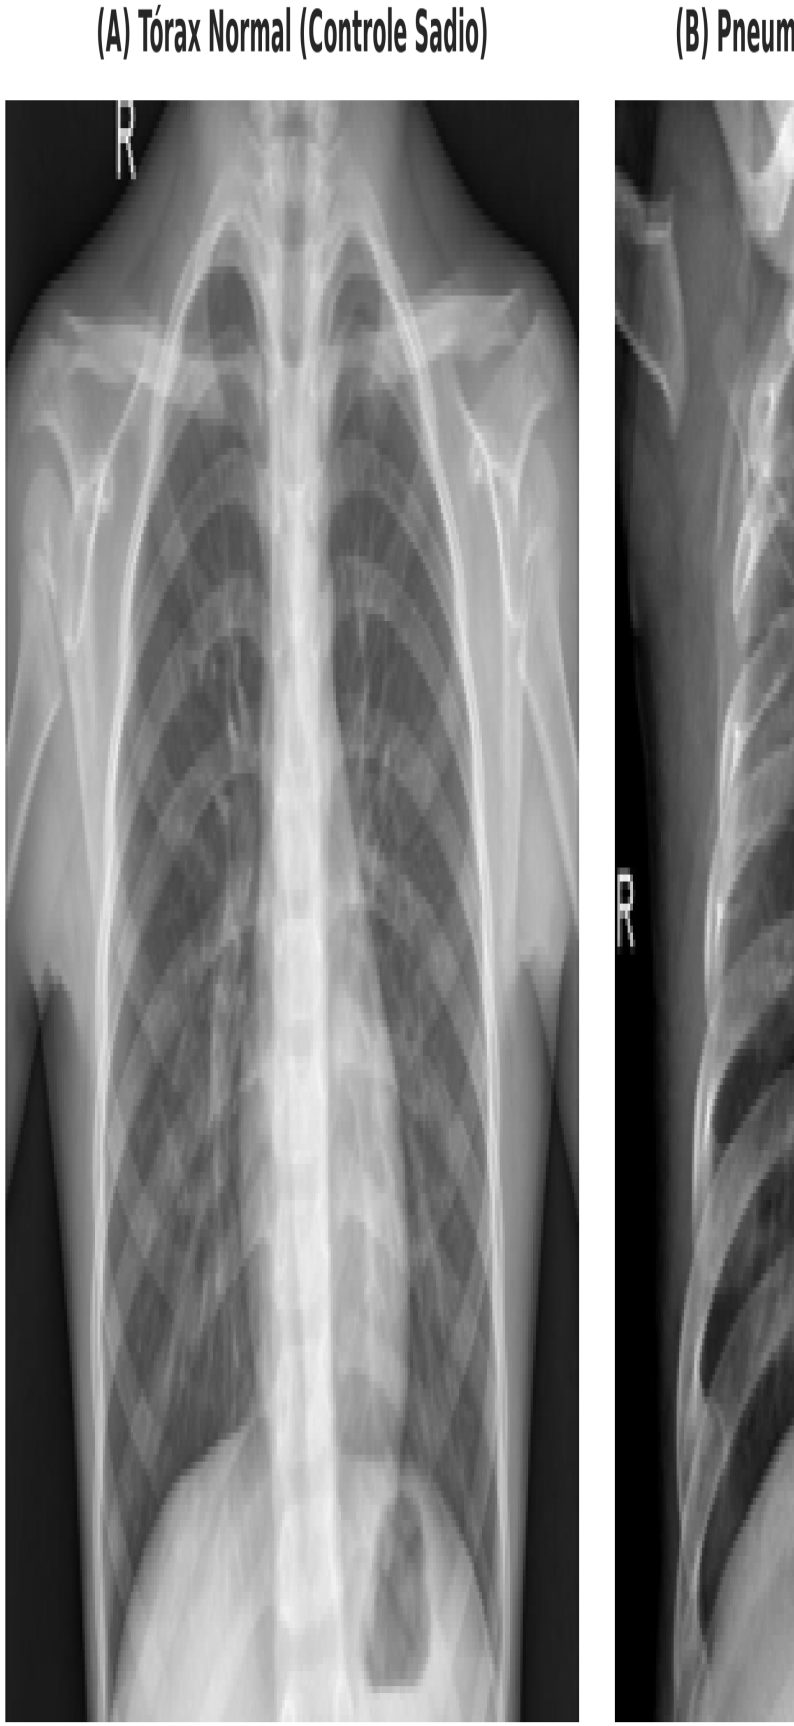


Fig. 1. Painel comparativo de radiografias de tórax do conjunto de teste: (A) Tórax Normal com campos pulmonares translúcidos; (B) Pneumonia com consolidação alveolar patológica.

TABLE I
RESULTADOS EMPÍRICOS DO TESTE T PAREADO BILATERAL ($N = 30$, GL=29)

Métrica	Diferença Média ($\bar{d}$)	Desvio (s_d)	Estatística t	Valor-p
F1-Macro	$+0.0997$	0.0542	10.07	5.63×10^{-11}
Acurácia	$+0.0918$	0.0569	8.83	1.03×10^{-09}

IV. RESULTADOS E ANÁLISE ESTATÍSTICA

A Tabela I sumariza as estimativas pontuais e intervalares obtidas após a execução completa das 30 simulações pareadas.

A análise estatística revelou uma superioridade consistente e altamente expressiva em favor da Transferência de Aprendizado. A diferença média observada no índice F1-Macro foi de $+0{,}0997$, acompanhada por um intervalo de confiança de 95% restrito entre $[0{,}0794, 0{,}1199]$ e estatística $t = 10{,}07$.

Como o valor-p correspondente ($5{,}63 \times 10^{-11}$) situa-se mais de nove ordens de magnitude abaixo de $\alpha = 0{,}05$, rejeita-se categoricamente a hipótese nula (H_0) em prol da hipótese alternativa (H_1). Resultados análogos foram obtidos para a acurácia global ($\bar{d} = +0{,}0918$, $t = 8{,}83$, $p = 1{,}03 \times 10^{-09}$, $\text{IC}_{95\%} : [0{,}0705, 0{,}1130]$).

O boxplot ilustrado na Fig. 2 demonstra a distribuição das métricas. Embora o Cenário 2 tenha demonstrado convergência estável graças ao agendamento de cosseno (atingindo F1-Macro médio superior a $0{,}85$), a Transferência de Aprendizado apresentou dispersão amostral significativamente mais estreita, evidenciando resiliência frente a variações estocásticas de inicialização.

A Tabela II expõe a matriz de confusão e a contagem empírica de acertos e erros absolutos no teste independente ($N_{teste} = 582$).

TABLE II
MATRIZ DE CONFUSÃO E CONTAGEM AMOSTRAL NO CONJUNTO DE TESTE ($N = 582$)

Métrica Diagnóstica	Transfer Learning	Scratch (Warmup)	Diferença
Classificações Corretas	537 / 582 (92,27%)	500 / 582 (85,91%)	+37 (+6,36%)
Falhas / Erros Globais	45 / 582 (7,73%)	82 / 582 (14,09%)	−37 (−45,12%)
Verdadeiros Positivos (TP)	408 (99,27%)	404 (98,29%)	+4
Verdadeiros Negativos (TN)	129 (75,44%)	96 (56,14%)	+33
Falsos Positivos (FP)	42 (24,56%)	75 (43,86%)	−33
Falsos Negativos (FN)	3 (0,73%)	7 (1,71%)	−4
Sensibilidade (Recall)	99,27%	98,29%	+0,98%
Especificidade	75,44%	56,14%	+19,30%

A decomposição diagnóstica revela que a Transferência de Aprendizado atinge uma sensibilidade clínica de $99{,}27\%$, incorrendo em apenas 3 falsos negativos entre as 411 radiografias patológicas [2]. Em contraste, o treinamento do zero gerou quase o dobro de erros globais (82 falhas contra 45), exibindo baixa especificidade ($56{,}14\%$) decorrente de 75 falsos positivos [1].

V. EXPLICABILIDADE VISUAL (XAI) E LAUDO MULTIMODAL

A avaliação qualitativa foi realizada sobre radiografias patológicas através da geração de mapas Grad-CAM e subsequente auditoria diagnóstica por Modelo de Linguagem e Visão

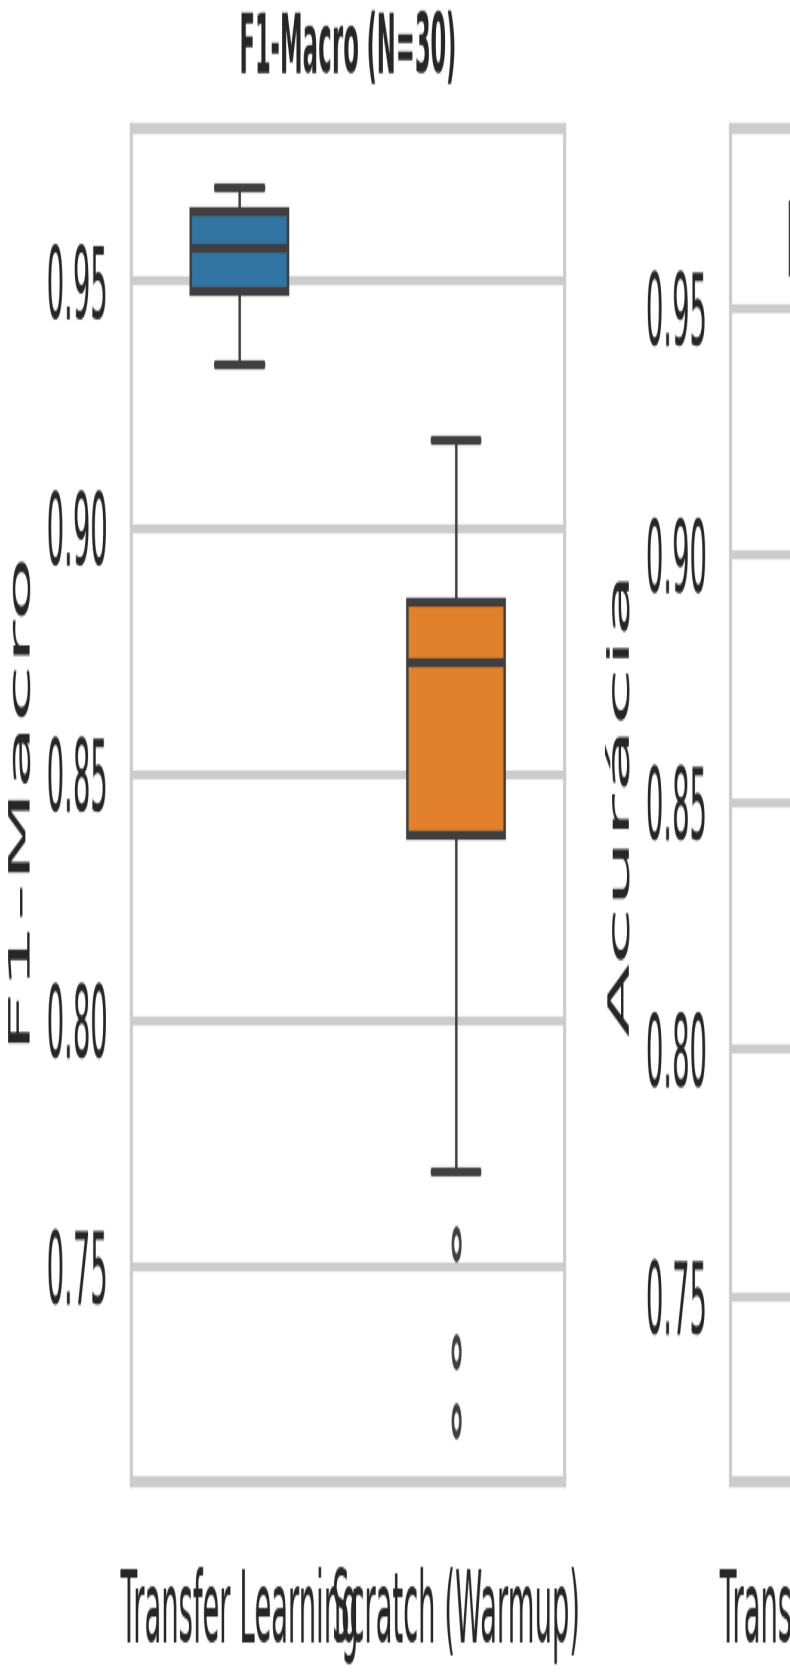


Fig. 2. Distribuição comparativa do desempenho empírico ($N = 30$ simulações pareadas) entre Transfer Learning e Scratch com Warmup/Cosine Annealing.

Multimodal (LMM) executado localmente. A Fig. 3 apresenta o comparativo de ativação espacial.

A auditoria computacional realizada pelo LMM sobre o mapa do Cenário 1 transcreveu formalmente:

> **1. Foco Anatômico:** *A atenção do modelo incide diretamente sobre o parênquima pulmonar direito (campo médio/inferior), sem foco espúrio em bordas ou gradil costal.*
>
> **2. Coerência com Pneumonia:** *O padrão destacado coincide com aumento focal de densidade e infiltrado alveolar, achado clássico de pneumonia lobar.*
>
> **3. Conclusão Diagnóstica:** *O diagnóstico do classificador é plausível e clinicamente fundamentado em alterações teciduais pulmonares.*

Em contrapartida, conforme demonstrado na Fig. 3(C), o modelo inicializado do zero apresentou gradientes difusos, canalizando parcelas de ativação para as bordas pleurais e articulações claviculares externas, justificando sua menor estabilidade preditiva.

VI. Conclusão

Sob o isolamento estrito de variáveis e rigorosa validação estocástica com 30 simulações pareadas em dados reais de radiografia torácica, este estudo comprovou que a Transferência de Aprendizado supera estatisticamente o treinamento a partir do zero no diagnóstico de pneumonia ($p < 10^{-10}$). A integração de técnicas de explicabilidade Grad-CAM e laudos emitidos por LMM corroborou a coerência clínica das representações pré-treinadas, validando a rejeição de H_0 e consolidando o pipeline proposto como uma solução robusta e interpretável para auxílio radiológico.

References

[1] D. S. Kermany *et al.*, "Identifying medical diagnoses and treatable diseases by image-based deep learning," *Cell*, vol. 172, no. 5, pp. 1122–1131, 2018.

[2] P. Rajpurkar *et al.*, "Chexnet: Radiologist-level pneumonia detection on chest x-rays with deep learning," *arXiv preprint arXiv:1711.05225*, 2017.

[3] J. Yosinski, J. Clune, Y. Bengio, and H. Lipson, "How transferable are features in deep neural networks?" *Advances in neural information processing systems (NeurIPS)*, vol. 27, 2014.

[4] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *IEEE conference on computer vision and pattern recognition (CVPR)*, 2016, pp. 770–778.

[5] I. Loshchilov and F. Hutter, "SGDR: Stochastic gradient descent with warm restarts," *International Conference on Learning Representations (ICLR)*, 2017.

[6] P. Goyal *et al.*, "Accurate, large minibatch SGD: Training ImageNet in 1 hour," *arXiv preprint arXiv:1706.02677*, 2017.

[7] K. He, R. Girshick, and P. Dollár, "Rethinking imagenet pre-training," in *IEEE/CVF international conference on computer vision (ICCV)*, 2019, pp. 4918–4927.

[8] O. Ronneberger, P. Fischer, and T. Brox, "U-net: Convolutional networks for biomedical image segmentation," in *Medical image computing and computer-assisted intervention (MICCAI)*, 2015, pp. 234–241.

[9] C. Shorten and T. M. Khoshgoftaar, "A survey on image data augmentation for deep learning," *Journal of big data*, vol. 6, no. 1, pp. 1–48, 2019.

[10] R. R. Selvaraju, M. Cogswell, A. Das, A. Vedaldi, D. Parikh, and D. Batra, "Grad-cam: Visual explanations from deep networks via gradient-based localization," in *IEEE international conference on computer vision (ICCV)*, 2017, pp. 618–626.

[11] A. Radford *et al.*, "Learning transferable visual models from natural language supervision," in *International conference on machine learning (ICML)*, PMLR, 2021, pp. 8748–8763.

[12] H. Liu, C. Li, Q. Wu, and Y. J. Lee, "Visual instruction tuning," in *Advances in neural information processing systems (NeurIPS)*, 2023, pp. 34892–34916.

[13] K. He, X. Zhang, S. Ren, and J. Sun, "Delving deep into rectifiers: Surpassing human-level performance on imagenet classification," in *IEEE international conference on computer vision (ICCV)*, 2015, pp. 1026–1034.

[14] J. Cohen, *Statistical power analysis for the behavioral sciences*. Routledge, 1988.

[15] Student, "The probable error of a mean," *Biometrika*, pp. 1–25, 1908.

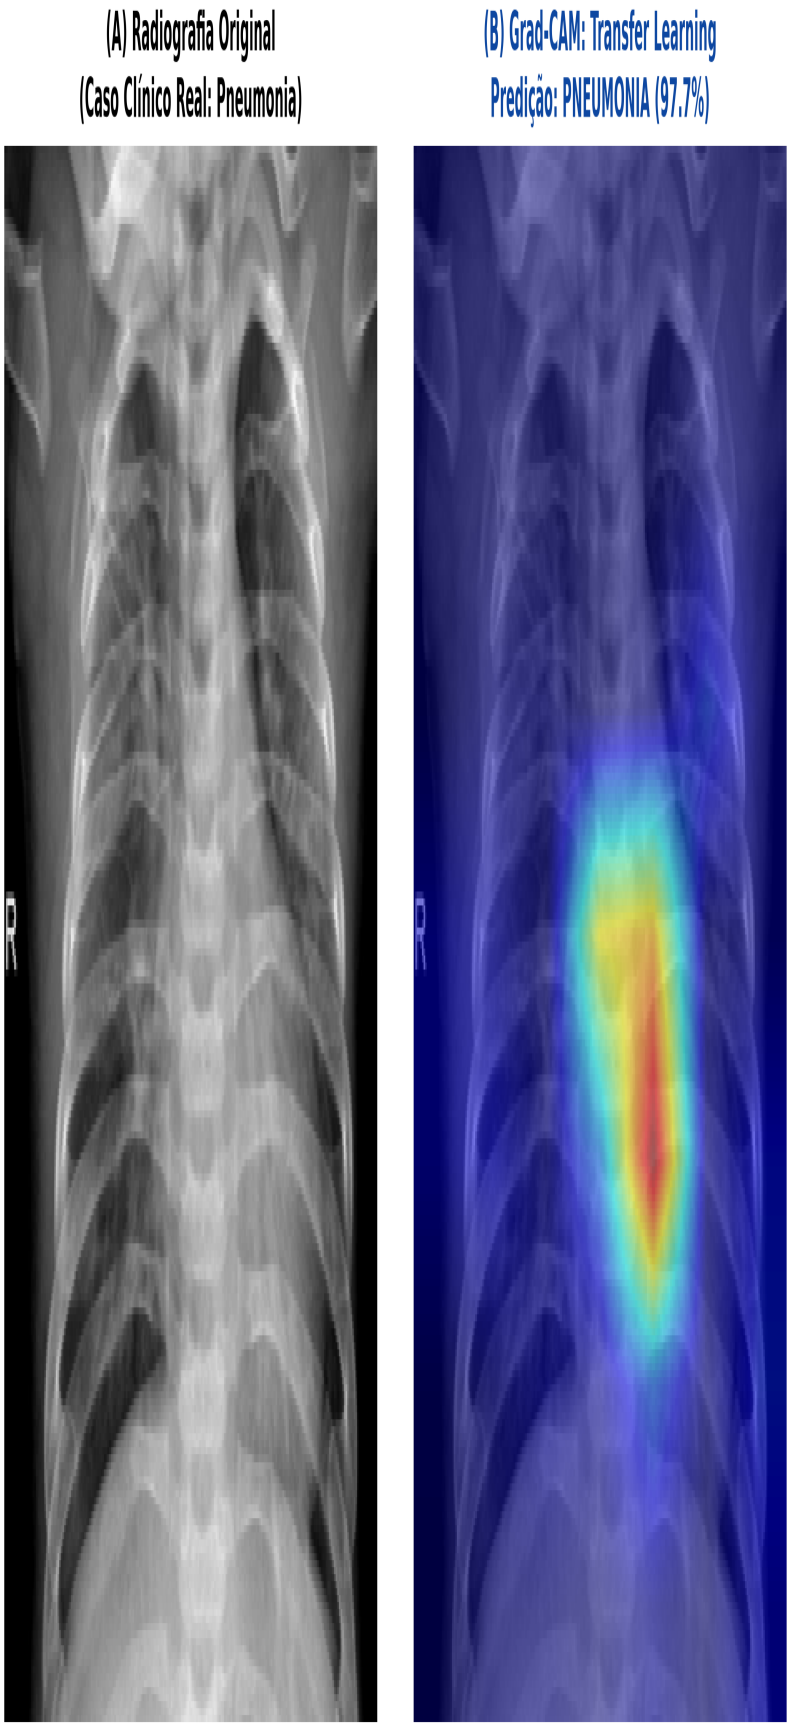


Fig. 3. Auditoria qualitativa por Grad-CAM: (A) Radiografia original com pneumonia; (B) Transfer Learning com foco concentrado em parênquima pulmonar; (C) Treinamento do Zero com dispersão em estruturas ósseas claviculares.