

Foundation Models em Visão

Vision Transformers, modelos multimodais (CLIP e LMMs) e Stable Diffusion — uma introdução construída sobre o que a disciplina já percorreu

EL1 – Inteligência Artificial · CESAR School
Prof. Rodrigo Paiva · rfapo@cesar.school
outubro/2026 · 40 min de aula + 20 min de discussão

Ref.: [1] Bommasani et al. 2021 · [27] CS886 (UWaterloo) · [28] Krishna 2025

Antes de começar: o que a disciplina já percorreu — e onde cada bloco entra hoje

Classificação (CNN)
imagem → features → camada de saída com uma linha por classe; a convolução embute localidade e invariância a translação

→ hoje: ViT (8–9) · zero-shot do CLIP (13)

Segmentação (U-Net)
encoder–decoder com skip connections; decisão por pixel; vocabulário fechado de classes

→ hoje: U-Net do SD (19) · SAM (24)

Detecção
localizar + classificar em um conjunto fixo (COCO: 80 classes); backbones multi-escala

→ hoje: Swin (9) · SAM (24)

GAN
gerador vs. discriminador (min–max); amostras nítidas e rápidas; treino instável, mode collapse

→ hoje: trilema da geração (17)

VAE
encoder → latente z → decoder; reconstrução como objetivo; latente compacto

→ hoje: MAE (10) · latente do SD (19)

RNN / seq2seq
processar sequências token a token; decoder que gera um símbolo por vez

→ hoje: LLM dentro dos LMMs (15)

Transformers
atenção: cada token consulta todos (custo N^2); encoder, decoder e cross-attention; embedding de posição

→ hoje: ViT (8) · CLIP (12) · Flamingo (15) · SD (20)

Few-shot
embedding + distância decidem a classe com poucos exemplos (protótipos, siamesas)

→ hoje: aprendizado contrastivo / CLIP (12)

Transfer learning
pré-treinar grande; congelar ou ajustar na tarefa pequena; linear probe vs. fine-tuning

→ hoje: FM (4–5) · ViT (9) · LLaVA (15) · LoRA (22)

Ensemble learning
combinar modelos; professor → aluno (destilação) comprime o conjunto em um modelo

→ hoje: DeiT (9) · DINO (10)

xAI
mapas de saliência e de atenção como interpretação — com ressalvas

→ hoje: atenção do ViT (9) · DINO (10)

Ética em IA
vieses de dados, uso indevido, responsabilidade e transparência

→ hoje: CLIP (14) · dados do SD (19) · riscos (25)

O que será novo hoje: auto-supervisão · aprendizado contrastivo · destilação · difusão (prever o ruído) · classifier-free guidance — cada um ganha uma tag CONCEITO NOVO quando aparece

Ref.: [2] Transformers · [19] U-Net · [13] GAN · [14] VAE · [33] Snell et al. 2017 (few-shot) · [25] Hinton et al. 2015 (destilação) · [34] Selvaraju et al. 2016 (Grad-CAM) · [1] Bommasani et al. 2021 (ética)

Prof. Rodrigo Paiva
outubro/2026

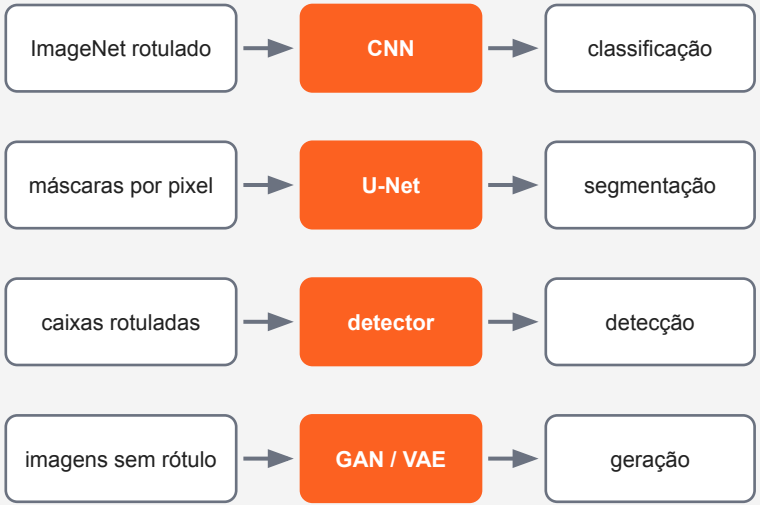
1. Por que foundation models

O que muda em relação ao percurso da disciplina: um pré-treino, muitas tarefas

Ref.: [1] Bommasani et al. 2021 · [28] Krishna 2025

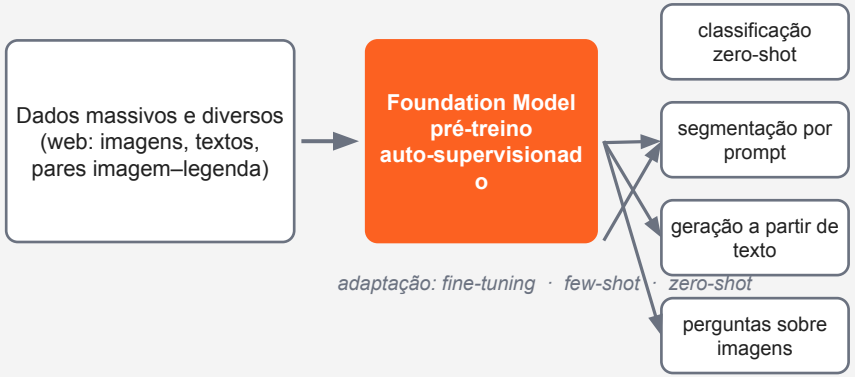
Até aqui, um modelo por tarefa; com foundation models, um pré-treino e muitas tarefas

Paradigma especialista — o percurso da disciplina



1 dataset → 1 modelo → 1 tarefa (mesmo com transfer learning, adapta-se uma tarefa por vez)

Paradigma foundation model



Conexão transfer learning já era o mecanismo de adaptação; o que muda é a escala dos dados, a auto-supervisão e a generalidade do modelo resultante.

Três ingredientes definem um foundation model: generalidade, escala e auto-supervisão

1 Generalidade *sempre*

Um único modelo serve a muitas tarefas, muitas vezes sem rotular dados novos (zero-shot) ou com poucos exemplos (few-shot).

2 Escala *quase sempre*

Centenas de milhões a bilhões de parâmetros; centenas de milhões de exemplos; treino distribuído em muitas GPUs.

3 Auto-supervisão *quase sempre*

O rótulo vem do próprio dado: prever o próximo token, reconstruir um patch mascarado, casar imagem com legenda.

CONCEITO NOVO

Conexão a reconstrução do VAE já é um objetivo auto-supervisionado; o fine-tuning do transfer learning já é a etapa de adaptação. O novo aqui é a combinação dos três ingredientes.

Mapa da aula

ViT
a imagem como sequência — o backbone

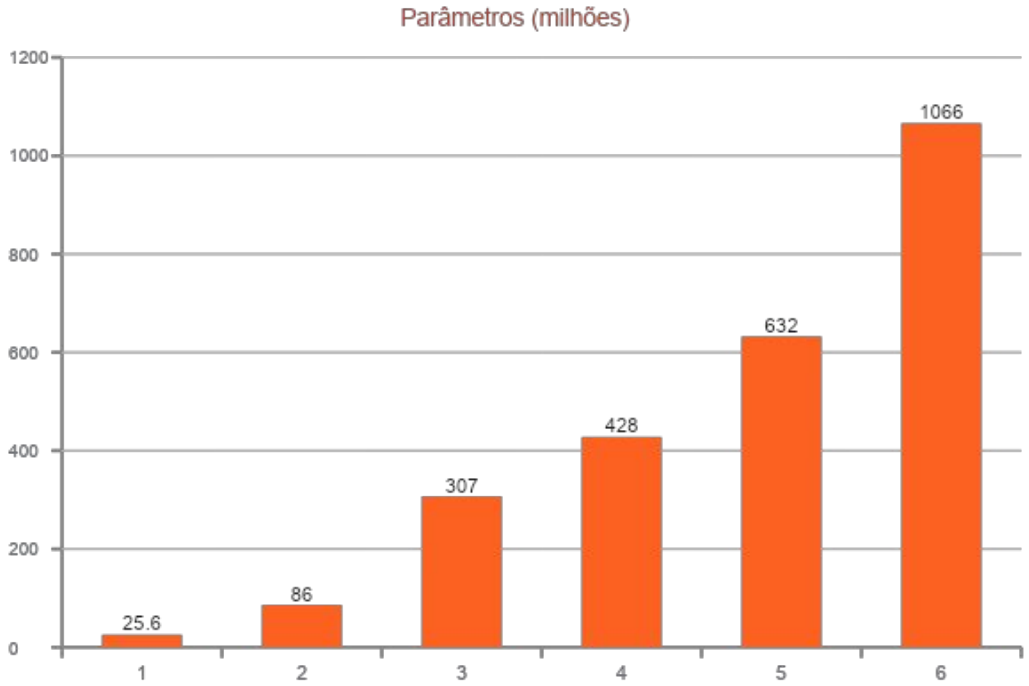
CLIP e LMMs
alinhar imagem e texto; perguntar sobre imagens

Stable Diffusion
gerar imagens a partir de texto

SAM e riscos
segmentar qualquer coisa; o que pode dar errado

Ref.: [1] Bommasani et al. 2021 (§1.1) · [28] Krishna 2025, p. 6 · [12] Li et al. 2023 (§1)

Escala: parâmetros e dados crescem duas ordens de grandeza em relação ao que a disciplina usou



1,3M → 300M

imagens de pré-treino: ImageNet-1k → JFT-300M (ViT)

400M

pares (imagem, texto) coletados da web para o CLIP

~2B

pares filtrados do LAION-5B usados no Stable Diffusion

32 GB ≈ 1,4B

parâmetros treináveis em uma GPU: além disso, paralelismo, precisão mista e kernels (fora do escopo)

SD v1.5 = U-Net 860M + encoder de texto CLIP 123M + VAE 84M. ResNet-50 é a referência do que a disciplina treinou/adaptou.

Ref.: [3] Dosovitskiy et al. 2020 (Tab. 1, §4) · [8] Radford et al. 2021 (§2) · [17] Rombach et al. 2022 · [27] CS886 L12 (ZeRO)

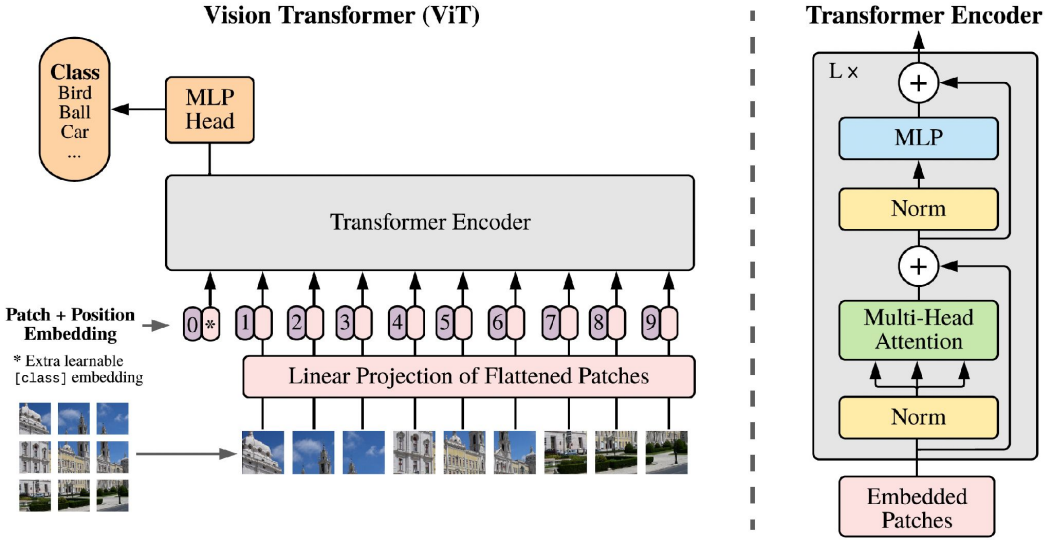
Prof. Rodrigo Paiva
outubro/2026

2. Vision Transformers

A imagem como sequência: o backbone de quase tudo que vem depois

Ref.: [3] Dosovitskiy et al. 2020 · [6] He et al. 2021 · [7] Caron et al. 2021

ViT: a imagem vira uma sequência de patches e entra no encoder do Transformer



Dosovitskiy et al. 2020, Fig. 1: patches → projeção linear → + posição → encoder (só encoder, L blocos) → [CLS] → MLP head.



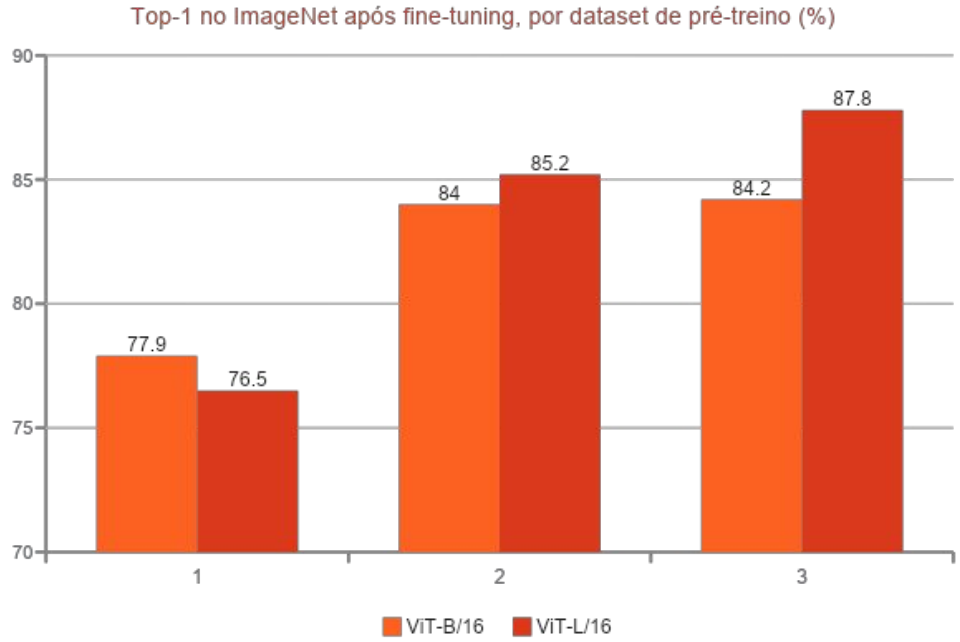
Figura computada: 224×224 com grade 16×16 → 14×14 = 196 patches

- Patch 16×16×3 = 768 valores → projeção linear para D; mais um embedding de posição aprendido
- Token [CLS] (classification token): um vetor extra, aprendido, que não vem de patch nenhum; sua saída resume a imagem e alimenta o classificador — o papel do global pooling na CNN
- Só o encoder: L blocos de atenção + MLP, o mesmo bloco usado em texto; custo da atenção cresce com N^2
- Nome ViT-B/16: B = Base (12 camadas, D = 768, 12 cabeças, 86M parâmetros) e /16 = patch de 16×16. Tamanhos: S (Small), B, L (Large, 307M), H (Huge, 632M); 196 + 1 tokens por imagem
- Alternativa descartada: pixels como tokens (Image GPT reduz a 32×32 = 1.024 tokens e perde detalhe)

Conexão o bloco do encoder é o mesmo da aula de Transformers; a única peça nova é a tokenização por patches.

Ref.: [3] Dosovitskiy et al. 2020 (Fig. 1, §3.1) · [2] Vaswani et al. 2017 · [26] Chen et al. 2020 (Image GPT). Figura: [3] Fig. 1, via CS886 L16 [27]

Sem o viés indutivo da CNN, o ViT depende de dados em escala — ou de truques de treino



Dados da Tab. 5 de [3]. Datasets de pré-treino: ImageNet-21k = 14M imagens em 21 mil classes; JFT-300M = base interna do Google, 300M imagens com ~18 mil rótulos ruidosos gerados automaticamente, não pública. Com 1,3M imagens o modelo maior é pior; com 300M, o maior vence (ViT-H/14, o Huge, chega a 88,5%).

- A CNN traz localidade, compartilhamento de pesos e invariância a translação de fábrica; o ViT precisa aprendê-las dos dados
- Com pouco dado, ViT fica abaixo de ResNets equivalentes; com dezenas a centenas de milhões de imagens, passa à frente
- DeiT (Data-efficient image Transformer, Meta 2020): mesma arquitetura do ViT, treinada só com ImageNet-1k graças a augmentation forte + destilação de um professor CNN (DeiT-B: 81,8% → 83,4%)
- Swin: atenção em janelas locais + fusão de patches dá hierarquia e custo linear — o backbone para detecção e segmentação

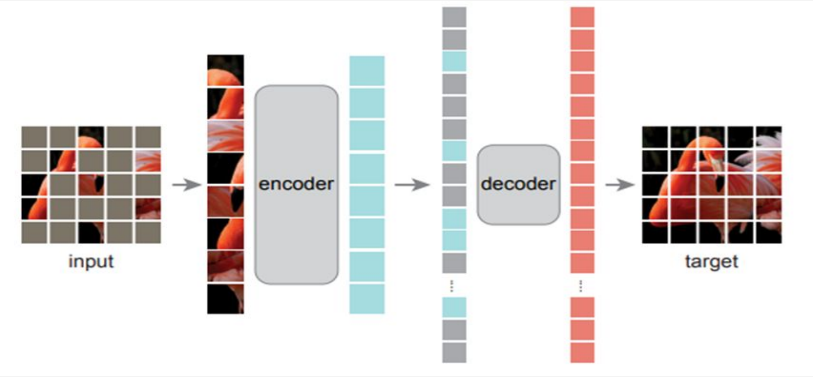
CONCEITO NOVO

Conexão destilação = um aluno aprende das saídas suaves de um professor (a mesma lógica de comprimir um ensemble em um modelo); o pré-treino grande + fine-tuning pequeno é o transfer learning em escala.

Ref.: [3] Dosovitskiy et al. 2020 (Tab. 5, Fig. 3–4) · [4] Touvron et al. 2020 (DeiT, Tab. 5) · [5] Liu et al. 2021 (Swin) · [25] Hinton et al. 2015

Auto-supervisão em visão: MAE reconstrói patches mascarados; DINO destila sem rótulos

MAE — Masked Autoencoder



He et al. 2021, Fig. 1

- Mascara 75% dos patches; o encoder (ViT) só vê os 25% visíveis — treino 3× mais rápido
- Um decoder leve reconstrói os pixels e é descartado; sobra o encoder para fine-tuning
- ViT-H (Huge, 632M parâmetros): 87,8% no ImageNet-1k sem dado externo — o nível que o ViT-L só atingiu com 300M imagens rotuladas

DINO — self-distillation with no labels



Caron et al. 2021, Fig. 1: atenção do [CLS] — supervisionado (acima) vs DINO (abaixo)

- Aluno e professor (média móvel do aluno) veem recortes diferentes da mesma imagem; o aluno imita o professor
- Sem rótulos, a atenção do [CLS] passa a delimitar o objeto; k-NN sobre as features já classifica bem
- Backbones assim (MAE, DINO) alimentam SAM e muitos modelos multimodais

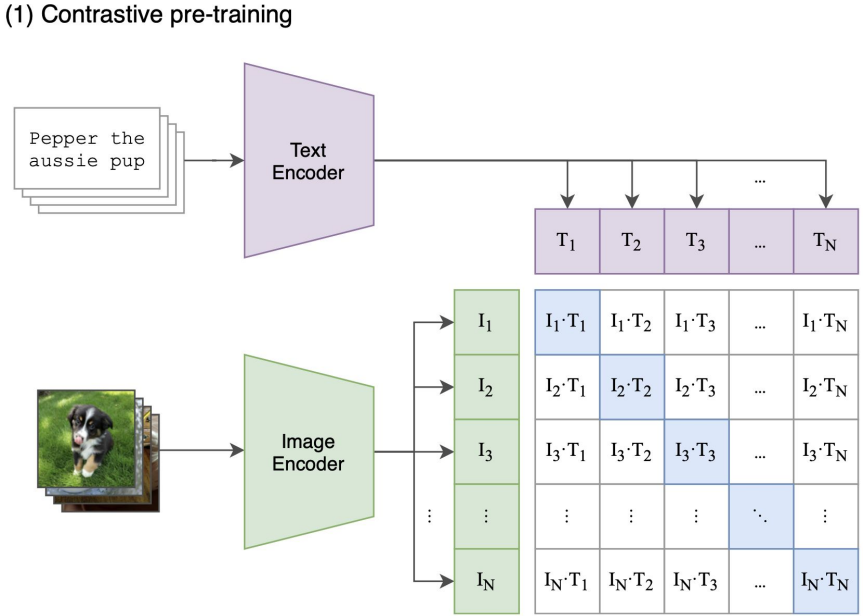
Prof. Rodrigo Paiva
outubro/2026

3. CLIP e modelos multimodais

Colocar imagem e texto no mesmo espaço; perguntar sobre imagens

Ref.: [8] Radford et al. 2021 · [10] Liu et al. 2023 · [11] Alayrac et al. 2022

CLIP: aprendizado contrastivo coloca imagem e texto no mesmo espaço vetorial



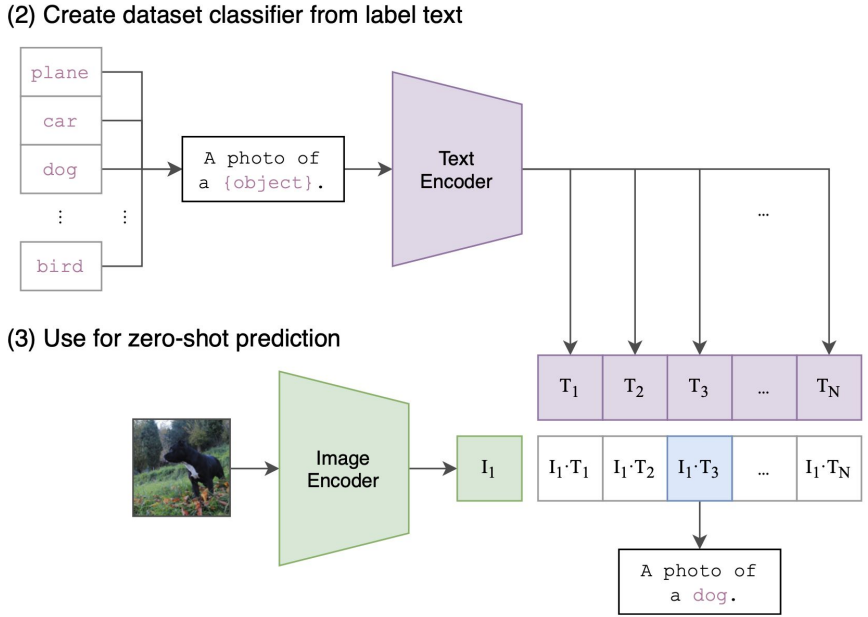
Radford et al. 2021, Fig. 1 (1): no batch, só a diagonal da matriz N×N são pares corretos.

CONCEITO NOVO

- CLIP = Contrastive Language-Image Pre-training (OpenAI, 2021)
- Contrastivo: num batch de N pares (imagem, legenda) há N × N combinações; só as N da diagonal são corretas e as $N^2 - N$ restantes são negativos. A loss aproxima as corretas e afasta as erradas
- Dois encoders — imagem (ViT ou ResNet) e texto (Transformer) — projetam para a mesma dimensão; similaridade por cosseno
- 400M pares (imagem, alt-text) coletados da web; batch de 32.768; loss simétrica (imagem→texto e texto→imagem)
- Por que não gerar a legenda? Prever qual texto casa com a imagem é ~4× mais eficiente do que prever as palavras
- Resultado do pré-treino: uma função de similaridade imagem–texto

Conexão few-shot já usava um espaço de embedding + distância para decidir a classe; o SimCLR (Simple framework for Contrastive Learning of visual Representations, 2020) faz o mesmo com duas vistas aumentadas da mesma imagem. O CLIP troca a segunda vista pelo texto.

Zero-shot: o encoder de texto vira o classificador — nenhum parâmetro novo é treinado



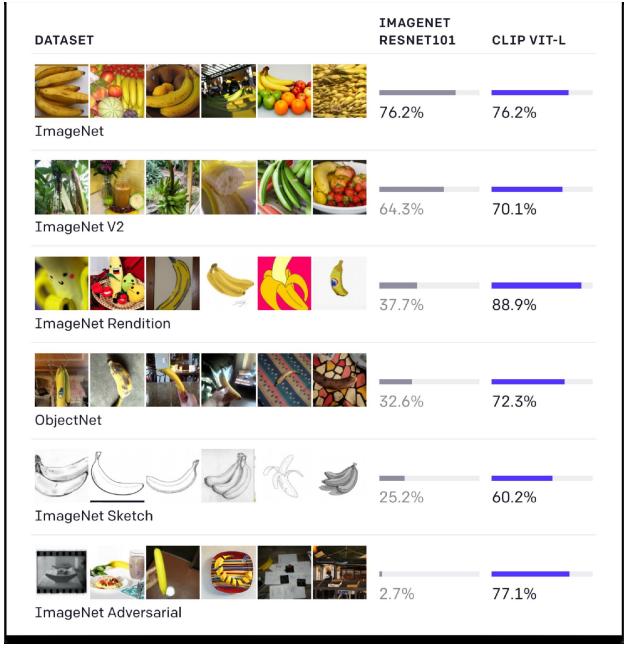
Radford et al. 2021, Fig. 1 (2)(3): as classes viram frases; a imagem é comparada com cada vetor de texto.

1. Escreva as classes como frases: “a photo of a {dog}” → um vetor por classe
2. Codifique a imagem com o encoder visual → um vetor
3. Classe = maior similaridade de cosseno (um 1-NN sobre os vetores de texto)

- O prompt importa: o template “a photo of a …” dá +1,3% no ImageNet; a média de 80 templates, +3,5%
- Vocabulário aberto: trocar as classes é trocar as frases — não há camada de saída com classes fixas

Conexão na classificação vista na disciplina, a última camada tinha uma linha por classe; aqui ela é substituída por vetores de texto. O linear probe sobre as features do CLIP é exatamente o transfer learning já praticado.

Zero-shot CLIP iguala a ResNet-50 e é mais robusto a shifts — mas lê a legenda como saco de palavras



Radford et al. 2021, Fig. 13: ResNet-101 (ImageNet) vs CLIP ViT-L zero-shot em variantes do ImageNet.

Winoground: mesmas palavras, ordem diferente



"there is a mug in some grass"



"there is some grass in a mug"

O CLIP dá quase a mesma pontuação para os dois pares: composição (quem está dentro de quem) não está no espaço aprendido.

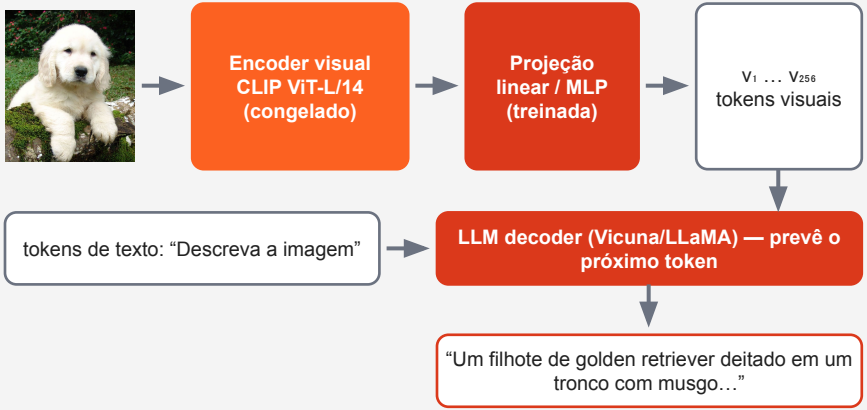
- 76,2% zero-shot no ImageNet, igual à ResNet-50 supervisionada — sem usar nenhum dos 1,28M rótulos
- Sob mudança de domínio (sketch, ObjectNet, adversarial) a vantagem cresce: o modelo não decorou o estilo do ImageNet
- Limites: composição, contagem, detalhe fino e tarefas ausentes da web; uma legenda por imagem é supervisão fraca

Conexão ética em IA: alt-text da web não é curado — vieses, estereótipos e usos sensíveis (vigilância) entram no modelo junto com os dados.

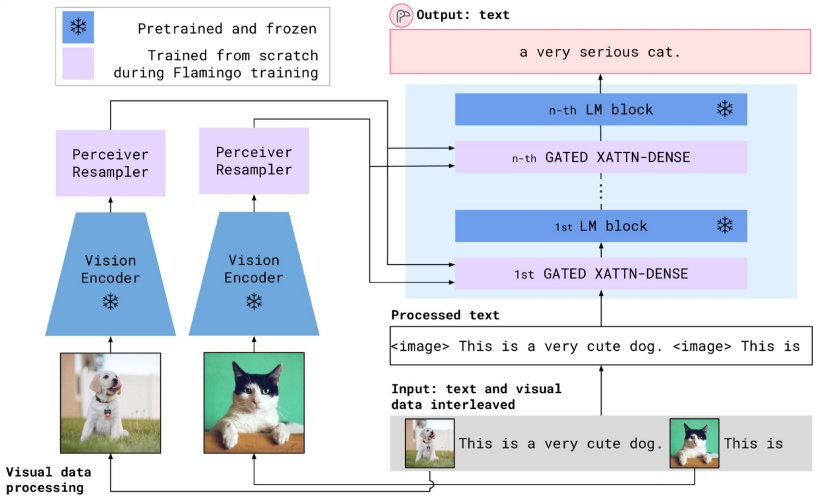
Ref.: [8] Radford et al. 2021 (§3.1.3 ImageNet; §3.3 e Fig. 13 robustez; §6 limitações; §7 impactos) · [24] Thrush et al. 2022 (Winoground, Fig. 1) · figuras via Krishna 2025 [28], p. 37 e 47

LMMs: um encoder visual acoplado a um LLM — LLaVA injeta tokens de imagem; Flamingo usa cross-attention

LLaVA — diagrama simplificado



Estágio 1: treina só a projeção com 595k pares (imagem, legenda)
Estágio 2: fine-tune projeção + LLM com 158k instruções geradas por GPT-4 (visual instruction tuning)



Alayrac et al. 2022, Fig. 3: LM e encoder visual congelados; camadas de cross-attention com gate (treinadas) inserem a imagem entre os blocos do LM. Suporta few-shot in-context com imagens e textos intercalados.

Conexão o LLM é o decoder autoregressivo da aula de Transformers; a cross-attention do Flamingo é a mesma do decoder original; congelar partes e treinar só a ponte é a estratégia do transfer learning.

Ref.: [10] Liu et al. 2023 (LLaVA, Fig. 1, §4) · [11] Alayrac et al. 2022 (Flamingo, Fig. 3) · [12] Li et al. 2023 (§5) · figura: [11] Fig. 3 via Krishna 2025 [28]

Prof. Rodrigo Paiva
outubro/2026

4. Stable Diffusion

Gerar imagens a partir de texto com peças já conhecidas: VAE, U-Net e cross-attention

Ref.: [15] Ho et al. 2020 · [17] Rombach et al. 2022 · [18] Ho & Salimans 2022

GAN e VAE geram imagens com trade-offs conhecidos; difusão é a terceira família



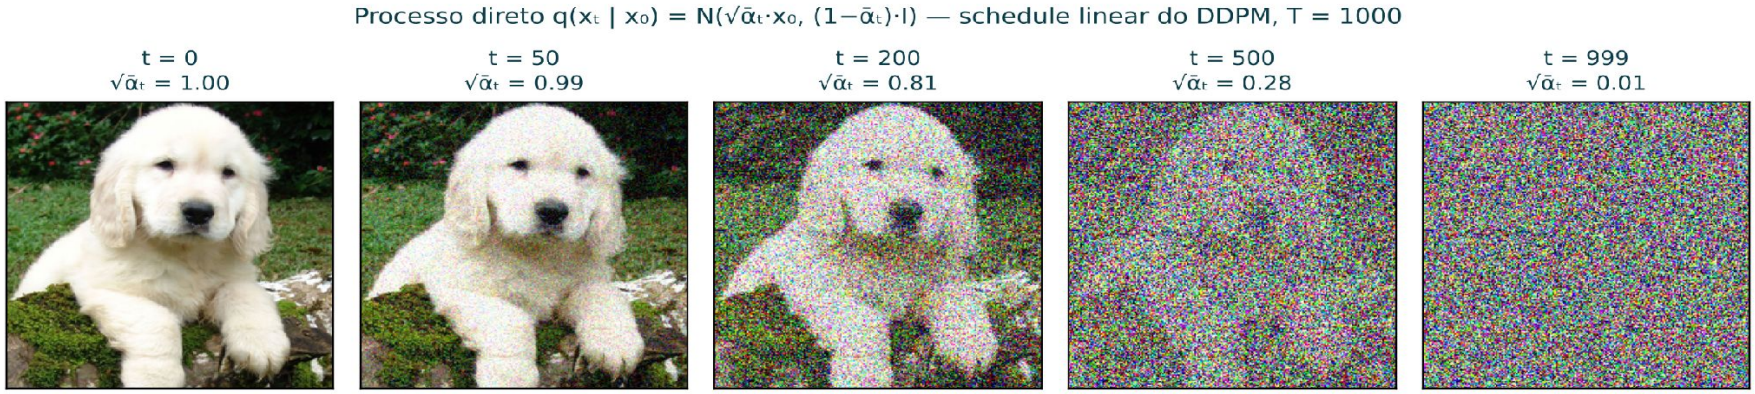
Cada família fica perto dos dois vértices em que é boa e longe do terceiro.

Família	Como gera	Força	Limite
GAN	gerador vs. discriminador (jogo min–max)	nítida e rápida: 1 passada	mode collapse; treino instável
VAE	encoder → z → decoder; maximiza o ELBO	estável; latente útil e compacto	amostras borradas
Difusão	reverte ruído gaussiano em T passos; prevê o ruído	qualidade + cobertura; treino estável (MSE)	lenta: dezenas a milhares de passadas

Conexão GAN e VAE foram vistos; a difusão reaproveita o decoder-de-ruído como um problema de regressão e o VAE como compressor (próximos slides).

Ref.: [13] Goodfellow et al. 2014 · [14] Kingma & Welling 2013 · [15] Ho et al. 2020 (DDPM, §1, §4)

Difusão: adicionar ruído é trivial; a rede aprende a prever o ruído para reverter o processo



Em palavras simples: imagine uma foto sendo coberta por chuvisco de TV até sumir. O modelo é um restaurador que, a cada passo, olha a foto chuviscada e aponta "isto aqui é chuvisco" — e ele aprendeu isso com milhões de exemplos em que sabíamos exatamente qual chuvisco tinha sido adicionado. Para criar uma imagem nova, entregamos só chuvisco e deixamos que ele "restaure" algo que nunca existiu.

Processo direto (fixo, sem aprendizado)

$x_t = \sqrt{\bar{\alpha}_t} \cdot x_0 + \sqrt{(1 - \bar{\alpha}_t)} \cdot \varepsilon, \quad \varepsilon \sim N(0, I)$

Em qualquer t basta uma amostra gaussiana; em t = T sobra só ruído. Não há nada para treinar aqui.

Processo reverso (aprendido)

CONCEITO NOVO

Treino: $L = E \| \varepsilon - \varepsilon_\theta(x_t, t) \|^2$ — uma regressão com MSE, sem discriminador

Amostragem: parte de ruído puro e remove um pouco por passo; a regra de quanto remover por passo chama-se scheduler (DDPM: 1000 passos; DDIM: 20–50 com quase a mesma qualidade).

Ref.: [15] Ho et al. 2020 (DDPM: Eq. 4 processo direto; Eq. 14 L_simple; Alg. 1–2; §4 schedule) · [16] Song et al. 2020 (DDIM, §4.2 poucos passos) · figura computada com o schedule linear de [15]

Stable Diffusion tem três peças — e as três já apareceram na disciplina

A VAE

visto em: geração (VAE)

Comprime a imagem 48×: 512×512×3 vira um latente 64×64×4. A difusão acontece no latente — é por isso que cabe em uma GPU.

B U-Net

visto em: segmentação

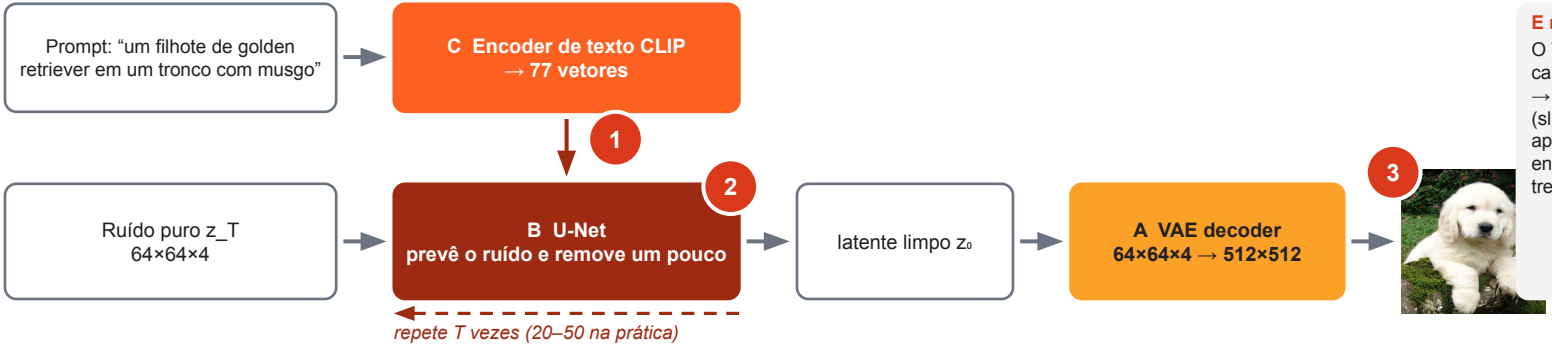
O "restaurador" do slide 18: recebe o latente ruidoso z_t, o passo t e o texto; devolve o ruído a remover. É chamada T vezes.

C Encoder de texto do CLIP

visto em: slide 12

Congelado. Transforma o prompt em 77 vetores que a U-Net consulta a cada passo — a cross-attention.

Como as peças se encaixam na geração de uma imagem



E no treino?
O VAE encoder faz o caminho inverso (imagem → z_0); somamos ruído (slide 18) e a U-Net aprende a prevê-lo. O encoder de texto não é treinado.

Os marcadores ①②③ são os próximos três slides: ① slide 20 — como o texto entra · ② slide 21 — como o prompt é obedecido · ③ slide 22 — o pipeline na prática

Dados de treino: ~2B pares (imagem, texto) do LAION-5B, base aberta coletada da web e filtrada com o próprio CLIP. Tamanhos (SD v1.5): U-Net 860M · encoder de texto 123M · VAE 84M.

Ref.: [17] Rombach et al. 2022 (LDM, Fig. 3, §3) · [30] CompVis 2022 (SD v1) · [22] Schuhmann et al. 2022 (LAION-5B) · [19] U-Net · [14] VAE · [8] CLIP

① Como o texto entra: cada posição da imagem pergunta “qual palavra me descreve?”

Zoom no diagrama do slide 19: ① Como o texto entra (cross-attention) · ② Como o prompt é obedecido (guidance) · ③ Na prática: pipeline e ecossistema

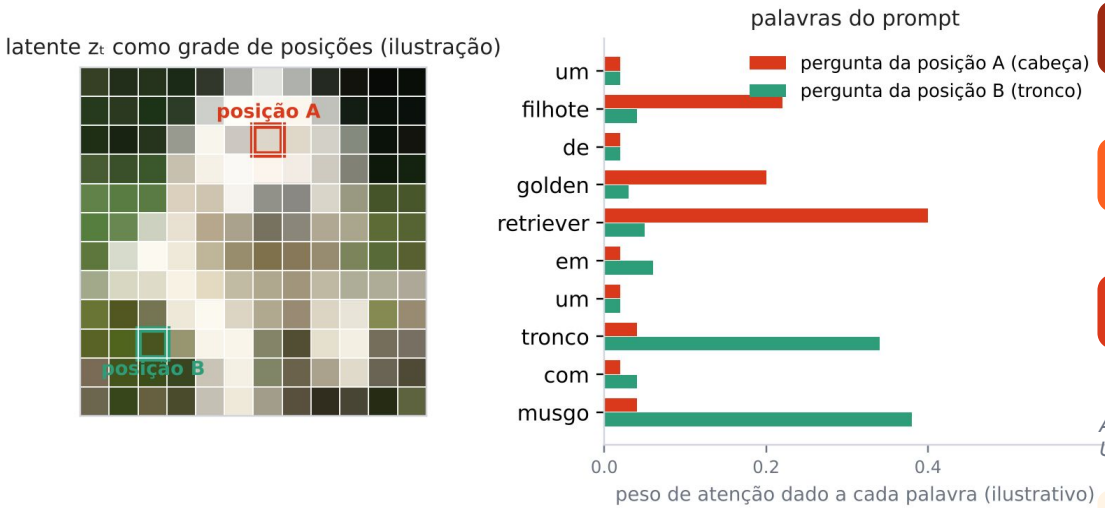


Ilustração sobre a foto do cão: a posição A (cabeça) dá peso a “filhote / golden / retriever”; a posição B (tronco) a “tronco / musgo”. Os pesos são inventados; o latente real tem 64×64 posições e o encoder de texto é o do CLIP, congelado.

Q — Cada posição do latente faz uma pergunta (query).

K, V — Cada palavra do prompt oferece uma chave (key), para ser encontrada, e um conteúdo (value), para ser copiado.

softmax — softmax(Q·K) dá um peso por palavra — as barras da figura. A posição absorve a soma dos conteúdos ponderada por esses pesos.

$$Attention(Q, K, V) = softmax(QK^T/\sqrt{d}) \cdot V$$ — *em todos os blocos da U-Net, em cada um dos T passos*

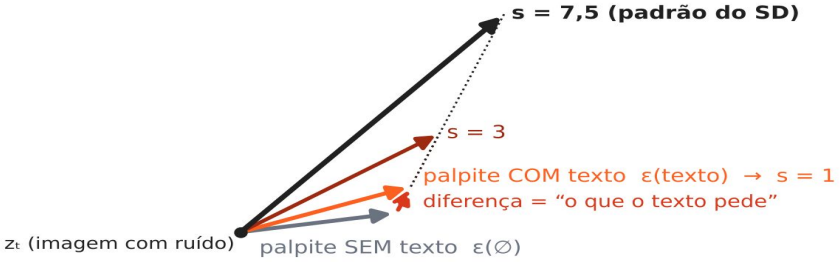
Conexão é a cross-attention do decoder do Transformer, sem mudança: Q de um lado, K e V do outro. No Flamingo quem perguntava era o texto; aqui é a imagem.

Ref.: [17] Rombach et al. 2022 (§3.3 Conditioning mechanisms) · [2] Vaswani et al. 2017 (§3.2.3 — cross-attention do decoder) · figura ilustrativa (pesos inventados para explicar o mecanismo)

② Como o prompt é obedecido: dois palpites de ruído por passo, e o guidance scale s exagera a diferença

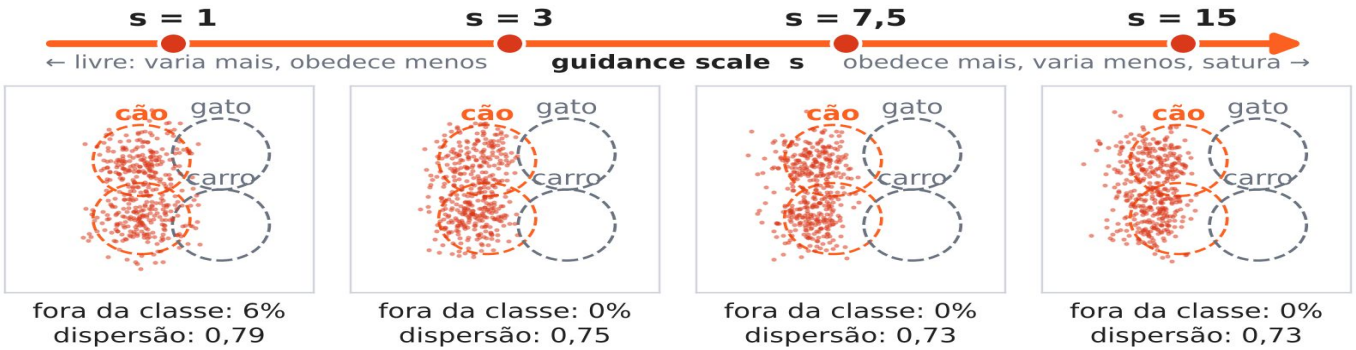
Zoom no diagrama do slide 19: ① Como o texto entra (cross-attention) | **② Como o prompt é obedecido (guidance)** | ③ Na prática: pipeline e ecossistema

$$\hat{\varepsilon} = \varepsilon(\varnothing) + s \cdot [\, \varepsilon(\text{texto}) - \varepsilon(\varnothing) \,]$$



CONCEITO NOVO

1. Treino: em 10–20% dos exemplos o prompt é apagado → a rede aprende a prever o ruído com e sem texto.
2. Geração: a cada passo, dois palpites (com e sem texto). A diferença é "o que o texto pede".
3. s multiplica a diferença. 1 = sem exagero; 7,5 = padrão do SD; alto = obedece demais e satura.



Como ler

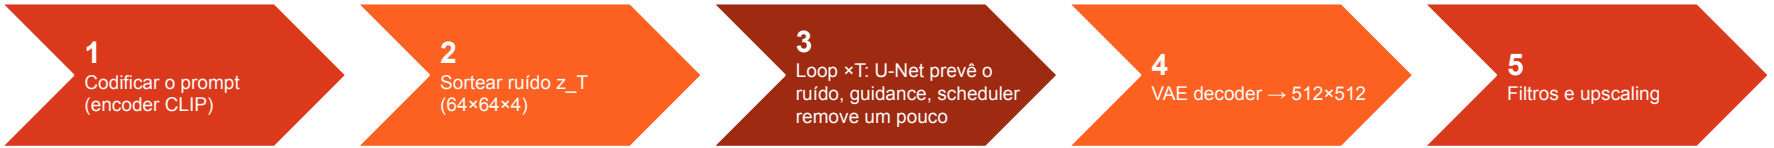
Simulação 2D. Tracejado = imagens reais; pontos = 400 imagens geradas pedindo "cão".

Da esquerda para a direita: o vazamento para gato/carro some (obedece mais) e a nuvem encolhe (varia menos); em s = 15 ela passa do alvo (satura).

Ref.: [18] Ho & Salimans 2022 (CFG: §3, Alg. 1–2; Fig. 1 — mesmo efeito em 2D) · [15] Ho et al. 2020 (amostrador DDPM do experimento) · [30] CompVis 2022 (scale 7,5 padrão)

③ Na prática: cinco passos para gerar uma imagem — e quatro formas de usar o modelo sem retreiná-lo

Zoom no diagrama do slide 19: ① Como o texto entra (cross-attention) · ② Como o prompt é obedecido (guidance) · **③ Na prática: pipeline e ecossistema**



O custo está no passo 3: a U-Net roda T vezes. Por isso importam o DDIM (menos passos) e as destilações de poucos passos (um aluno que faz em 1–4 passos o que o professor faz em 50).

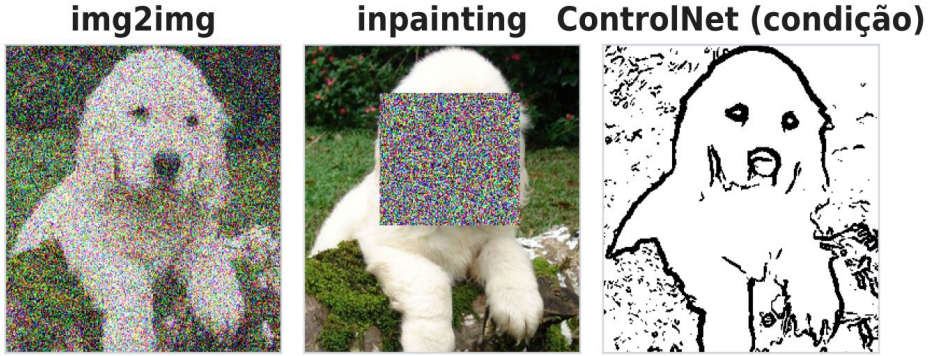


Figura computada sobre a foto do cão: as entradas de img2img (ruído parcial, t = 0,25·T), inpainting (ruído só na máscara) e ControlNet (mapa de bordas).

O que dá para plugar no modelo congelado

img2img — parte da sua imagem com ruído parcial, não de ruído puro — reestiliza mantendo a estrutura

inpainting — ruído só dentro da máscara; o resto da imagem fica como está

ControlNet — um ramo extra treinado para obedecer pose, bordas ou profundidade (fine-tuning parcial)

LoRA — ajuste de estilo ou de um personagem em poucos MB, somado às atenções (fine-tuning parcial)

Tendência: a U-Net dá lugar a um Transformer (DiT, SD3) — o ViT do bloco 2 volta como backbone da geração.

Ref.: [17] Rombach et al. 2022 · [30] CompVis 2022 (pipeline, scale 7,5, safety checker) · [20] Hu et al. 2021 (LoRA) · [21] Zhang et al. 2023 (ControlNet) · [29] Peebles & Xie 2022 (DiT)

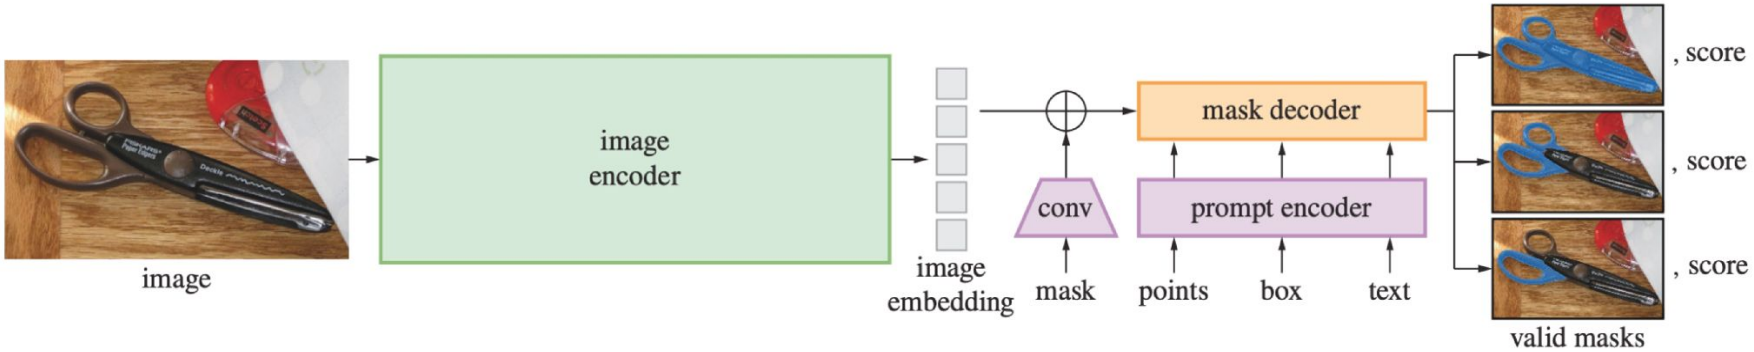
Prof. Rodrigo Paiva
outubro/2026

5. SAM, riscos e síntese

Segmentar qualquer coisa; o que pode dar errado; o mapa do que foi visto

Ref.: [23] Kirillov et al. 2023 · [1] Bommasani et al. 2021

SAM — Segment Anything Model: segmentação por prompt, treinada com 1,1 bilhão de máscaras



Kirillov et al. 2023, Fig. 4: encoder de imagem pesado (uma vez por imagem) + encoder de prompt + decoder de máscaras leve, que devolve 3 máscaras válidas com score.

- "Segment anything": segmentar qualquer objeto que um prompt indique. Encoder de imagem ViT-H (pré-treinado com MAE) roda uma vez; prompt encoder + decoder rodam em ~50 ms
- Prompts: pontos, caixas e máscaras (texto explorado no paper); 3 máscaras por prompt tratam a ambiguidade (parte, objeto, conjunto)
- SA-1B (Segment Anything 1 Billion): 11M imagens e 1,1B máscaras produzidas por um data engine — o modelo ajuda a anotar, a anotação melhora o modelo

Conexão segmentação na disciplina: classes fixas (ex.: 80 do COCO) e um modelo por dataset. Aqui: "qualquer coisa", zero-shot, sem saber o nome do objeto — o que abre a pergunta 4 da discussão.

Ref.: [23] Kirillov et al. 2023 (Segment Anything: §3 modelo, Fig. 4; §4 data engine; §5 SA-1B) · [6] He et al. 2021 (encoder MAE) · figura: [23] Fig. 4 via Krishna 2025 [28]

Riscos: homogeneização, dados da web não curados, emergência opaca e concentração de poder

H **Homogeneização**

Muitas aplicações herdam o mesmo modelo: um defeito, viés ou vulnerabilidade se propaga para todas de uma vez.

D **Dados não curados**

Alt-text da web e LAION: estereótipos, conteúdo sensível, material protegido por direitos autorais e memorização de exemplos de treino.

E **Emergência e opacidade**

Capacidades que ninguém projetou aparecem com a escala; explicar decisões de um modelo de bilhões de parâmetros ainda é problema aberto.

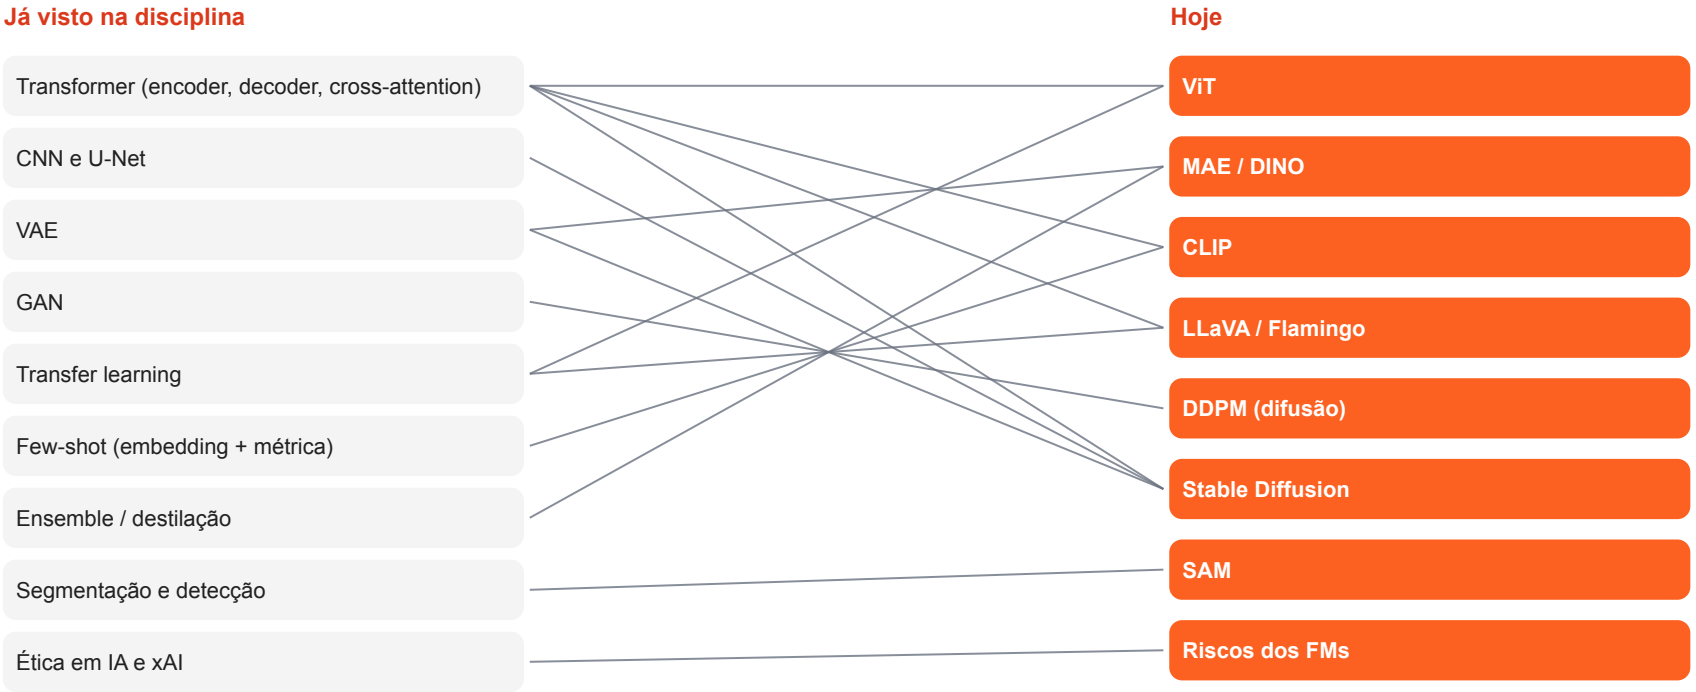
C **Custo e concentração**

Poucos atores conseguem treinar; pesos abertos vs. acesso por API determina quem pode auditar, reproduzir e corrigir.

Conexão ética em IA e xAI, já discutidas: os mesmos critérios, aplicados a modelos maiores, menos transparentes e reutilizados em cadeia.

Ref.: [1] Bommasani et al. 2021 (§1.1 emergência e homogeneização; §5 sociedade) · [8] Radford et al. 2021 (§7 Broader Impacts) · [22] Schuhmann et al. 2022 (LAION-5B, limitações e ética)

Síntese: cada peça de hoje se apoia em algo que já apareceu na disciplina



Conceitos novos de hoje: auto-supervisão · aprendizado contrastivo · destilação · difusão (prever o ruído) · classifier-free guidance

Ref.: [1] Bommasani et al. 2021 · [3] Dosovitskiy et al. 2020 · [8] Radford et al. 2021 · [17] Rombach et al. 2022 · [23] Kirillov et al. 2023

Prof. Rodrigo Paiva
outubro/2026

6. Discussão

20 minutos: cinco perguntas para os seminários

Ref.: [8] Radford et al. 2021 · [18] Ho & Salimans 2022 · [23] Kirillov et al. 2023 · [1] Bommasani et al. 2021

Discussão (20 min): cinco perguntas para os seminários

1. O CLIP nunca viu um rótulo do ImageNet e, mesmo assim, reconhece esboços e fotos “estranhas” melhor que a ResNet treinada nele (slide 14). O que ele aprendeu de diferente?

2. No Stable Diffusion, o que muda na amostra quando s → 1 e quando s → 20? O que isso revela sobre o trade-off diversidade vs. fidelidade?

3. Para um dataset médico pequeno, você partiria de MAE, DINO ou CLIP como backbone? Com que critério decidiria?

4. O SAM segmenta “qualquer coisa” sem saber o que é. Isso é segmentação semântica? O que falta e como você completaria?

5. Homogeneização: qual é o risco concreto de cinquenta aplicações herdarem o mesmo foundation model com o mesmo viés?

Ref.: [8] Radford et al. 2021 · [18] Ho & Salimans 2022 · [6] He et al. 2021 · [7] Caron et al. 2021 · [23] Kirillov et al. 2023 · [1] Bommasani et al. 2021

Exercício para o Colab: classificação zero-shot com CLIP em 12 linhas — e o que ele erra

CPU do Colab basta (~1 min). Roda sem login no Hugging Face.

```
!pip -q install transformers torch pillow
import torch, requests
from PIL import Image
from transformers import CLIPModel, CLIPProcessor
mid = "openai/clip-vit-base-patch32"
model, proc = CLIPModel.from_pretrained(mid), CLIPProcessor.from_pretrained(mid)
# imagem de exemplo do model card: dois gatos em um sofá
url = "http://images.cocodataset.org/val2017/000000039769.jpg"
img = Image.open(requests.get(url, stream=True).raw)
labels = ["a photo of a cat", "a photo of a dog",
          "a photo of two cats", "a photo of three cats"]
inp = proc(text=labels, images=img, return_tensors="pt", padding=True)
with torch.no_grad(): probs = model(**inp).logits_per_image.softmax(-1)[0]
for l, p in zip(labels, probs): print(f"{p:.2f}  {l}")
```

Roteiro (15 min, em dupla)

1. Rode e anote as probabilidades. Troque os rótulos por frases em português. O que muda? (o prompt importa — slide 13)
2. Contagem: o CLIP separa “two cats” de “three cats”? Compare com “cats on a couch” (limites — slide 14)
3. Suba uma foto sua (files.upload()) e invente 5 classes que não existem no ImageNet (ex.: frevo, maracatu). Vocabulário aberto na prática.

Entrega: 5 linhas no fórum com as probabilidades e uma hipótese para o erro da tarefa 2.

Opcional (GPU T4, ~30 s por imagem): gere o mesmo prompt com quatro valores de guidance scale e compare diversidade vs. fidelidade (pergunta 2 da discussão). As quatro imagens reproduzem, com imagens reais, o experimento 2D do slide 21.

```
!pip -q install diffusers accelerate
from diffusers import StableDiffusionPipeline
pipe = StableDiffusionPipeline.from_pretrained("stable-diffusion-v1-5/stable-diffusion-v1-5", torch_dtype=torch.float16).to("cuda")
for s in [1, 3, 7.5, 15]:
    pipe("a golden retriever puppy on a mossy log", guidance_scale=s, num_inference_steps=25).images[0].save(f"s{s}.png")
```

Ref.: [8] Radford et al. 2021 (§3.1.2 zero-shot; §3.1.4 prompts) · [31] model card openai/clip-vit-base-patch32 · [32] model card stable-diffusion-v1-5 · [18] Ho & Salimans 2022 (guidance scale)

Siglário e dicionário de termos usados na aula

Siglas

ViT — Vision Transformer

[CLS] — classification token — resume a imagem para classificar

DeiT — Data-efficient image Transformer

Swin — Shifted windows (Transformer hierárquico)

MAE — Masked Autoencoder

DINO — self-DIstillation with NO labels

EMA — média móvel exponencial (professor do DINO)

CLIP — Contrastive Language-Image Pre-training

LLM / LMM — Large Language / Multimodal Model

LLaVA — Large Language and Vision Assistant

SAM — Segment Anything Model

SA-1B — Segment Anything 1 Billion (dataset)

DDPM / DDIM — Denoising Diffusion Probabilistic / Implicit Models

LDM / SD — Latent Diffusion Model / Stable Diffusion

CFG — Classifier-Free Guidance

VAE / GAN — Variational Autoencoder / Generative Adversarial Net.

U-Net — encoder–decoder em U com skip connections

LoRA — Low-Rank Adaptation

DiT — Diffusion Transformer

JFT-300M / LAION-5B — 300M imagens (Google) / 5B pares imagem–texto

ImageNet-1k / -21k — 1,3M / 14M imagens rotuladas

MSE — erro quadrático médio (loss da difusão)

Termos

Auto-supervisão — o rótulo vem do próprio dado (próximo token, patch mascarado, par imagem–texto)

Contrastivo — aproximar pares corretos e afastar incorretos no espaço de embedding

Destilação — um aluno aprende das saídas suaves de um professor

Zero-shot / few-shot — resolver a tarefa sem exemplos / com poucos exemplos

Linear probe — treinar só um classificador linear sobre features congeladas

Fine-tuning — continuar o treino do modelo (todo ou parte) na nova tarefa

Patch / token — bloco 16×16 da imagem / vetor que entra no Transformer

Embedding — vetor que representa um item (imagem, texto, patch)

Cross-attention — Q de uma fonte (imagem); K e V de outra (texto)

Latente — representação comprimida (64×64×4) onde o SD difunde

Scheduler — regra de atualização por passo na amostragem (DDPM, DDIM…)

Guidance scale (s) — peso do prompt no CFG (≈ 7,5 no SD)

Viés indutivo — suposições embutidas na arquitetura (localidade na CNN)

Shift de distribuição — teste diferente do treino (sketch, ObjectNet)

Homogeneização — muitas aplicações herdam o mesmo modelo base

Data engine — modelo anota → humano corrige → modelo melhora (SAM)

Ref.: expansões conforme os papers de origem [3]–[8], [10], [15]–[18], [20], [23], [29]; homogeneização e emergência conforme [1]

Referências (1/2)

[1] Bommasani, R. et al. (2021). On the Opportunities and Risks of Foundation Models. arXiv:2108.07258
[2] Vaswani, A. et al. (2017). Attention Is All You Need. NeurIPS. arXiv:1706.03762
[3] Dosovitskiy, A. et al. (2020). An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. ICLR 2021. arXiv:2010.11929
[4] Touvron, H. et al. (2020). Training data-efficient image transformers & distillation through attention (DeiT). ICML 2021. arXiv:2012.12877
[5] Liu, Z. et al. (2021). Swin Transformer: Hierarchical Vision Transformer using Shifted Windows. ICCV. arXiv:2103.14030
[6] He, K. et al. (2021). Masked Autoencoders Are Scalable Vision Learners. CVPR 2022. arXiv:2111.06377
[7] Caron, M. et al. (2021). Emerging Properties in Self-Supervised Vision Transformers (DINO). ICCV. arXiv:2104.14294
[8] Radford, A. et al. (2021). Learning Transferable Visual Models From Natural Language Supervision (CLIP). ICML. arXiv:2103.00020
[9] Chen, T. et al. (2020). A Simple Framework for Contrastive Learning of Visual Representations (SimCLR). ICML. arXiv:2002.05709
[10] Liu, H. et al. (2023). Visual Instruction Tuning (LLaVA). NeurIPS. arXiv:2304.08485
[11] Alayrac, J.-B. et al. (2022). Flamingo: a Visual Language Model for Few-Shot Learning. NeurIPS. arXiv:2204.14198
[12] Li, C. et al. (2023). Multimodal Foundation Models: From Specialists to General-Purpose Assistants. arXiv:2309.10020
[13] Goodfellow, I. et al. (2014). Generative Adversarial Networks. NeurIPS. arXiv:1406.2661
[14] Kingma, D. P.; Welling, M. (2013). Auto-Encoding Variational Bayes. ICLR 2014. arXiv:1312.6114
[15] Ho, J.; Jain, A.; Abbeel, P. (2020). Denoising Diffusion Probabilistic Models. NeurIPS. arXiv:2006.11239
[16] Song, J.; Meng, C.; Ermon, S. (2020). Denoising Diffusion Implicit Models. ICLR 2021. arXiv:2010.02502
[17] Rombach, R. et al. (2022). High-Resolution Image Synthesis with Latent Diffusion Models. CVPR. arXiv:2112.10752

Ref.: todas as entradas verificadas em arxiv.org / PMLR / páginas dos cursos em 12/10/2026

Referências (2/2)

[18] Ho, J.; Salimans, T. (2022). Classifier-Free Diffusion Guidance. arXiv:2207.12598

[19] Ronneberger, O.; Fischer, P.; Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. MICCAI. arXiv:1505.04597

[20] Hu, E. J. et al. (2021). LoRA: Low-Rank Adaptation of Large Language Models. ICLR 2022. arXiv:2106.09685

[21] Zhang, L.; Rao, A.; Agrawala, M. (2023). Adding Conditional Control to Text-to-Image Diffusion Models (ControlNet). ICCV. arXiv:2302.05543

[22] Schuhmann, C. et al. (2022). LAION-5B: An open large-scale dataset for training next generation image-text models. NeurIPS. arXiv:2210.08402

[23] Kirillov, A. et al. (2023). Segment Anything. ICCV. arXiv:2304.02643

[24] Thrush, T. et al. (2022). Winoground: Probing Vision and Language Models for Visio-Linguistic Compositionality. CVPR. arXiv:2204.03162

[25] Hinton, G.; Vinyals, O.; Dean, J. (2015). Distilling the Knowledge in a Neural Network. arXiv:1503.02531

[26] Chen, M. et al. (2020). Generative Pretraining From Pixels (Image GPT). ICML, PMLR 119:1691–1703

[27] Chen, W. (2024). CS886: Recent Advances on Foundation Models — slides L12, L16 (Vision Transformers), L19 (Multimodal Pre-training). Univ. of Waterloo. https://cs.uwaterloo.ca/~wenhuche/teaching/cs886/

[28] Krishna, R. (2025). Lecture 16: Multi-Modal Foundation Models. Univ. of Washington (lecture_16.pdf).

[29] Peebles, W.; Xie, S. (2022). Scalable Diffusion Models with Transformers (DiT). ICCV 2023. arXiv:2212.09748

[30] CompVis (2022). Stable Diffusion v1 — repositório e model card (CLIP ViT-L/14, autoencoder f = 8, LAION-5B, scale 7.5). https://github.com/CompVis/stable-diffusion

[31] Hugging Face. Model card openai/clip-vit-base-patch32 (exemplo de uso com Transformers). https://huggingface.co/openai/clip-vit-base-patch32

[32] Hugging Face. Model card stable-diffusion-v1-5/stable-diffusion-v1-5 (exemplo de uso com Diffusers). https://huggingface.co/stable-diffusion-v1-5/stable-diffusion-v1-5

[33] Snell, J.; Swersky, K.; Zemel, R. (2017). Prototypical Networks for Few-shot Learning. NeurIPS. arXiv:1703.05175

[34] Selvaraju, R. R. et al. (2016). Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. ICCV 2017. arXiv:1610.02391

Ref.: todas as entradas verificadas em arxiv.org / PMLR / páginas dos cursos em 12/10/2026