Estudo Comparativo de Eficácia em Visão Computacional: Transferência em Foundation Models vs. Inicialização Aleatória

Experimento Científico Controlado com 30 Simulações Pareadas (N=30)
2ª Avaliação · Disciplina de Inteligência Artificial · Prof. Rodrigo Paiva

Equipe: Miguel Batista · Rafaela Vidal · Beatriz Pereira · Manuela Cavalcanti · Rafael Barros · Ygor Rosa · Hugo Alcântara
CESAR School · Outubro/2026 · {msb2, rbv2, bcbsp, mca2, ralb, yr, ha}@cesar.school

1. Contexto e Motivação Científica

Apresentador: Miguel Batista

- Paradigma Especialista (Percurso anterior da disciplina):
  - Uma arquitetura treinada do zero para cada tarefa isolada;
  - Dependência crítica de grandes bases anotadas por humanos e forte viés indutivo convolucional.

- Revolução dos Foundation Models em Visão:
  - Um único pré-treino escalado com auto-supervisão e alinhamento multimodal;
  - Vision Transformers (ViT) e CLIP: representações semânticas densas reutilizáveis.

- Desafio Real do Caso de Uso (Beans Dataset):
  - Diagnóstico foliar de patologias do feijoeiro: Mancha Angular, Ferrugem e Saudável;
  - Restrição severa de dados: apenas ~1.000 imagens de treino (1.034 treino / 128 teste).

2. Isolamento Experimental (Ceteris Paribus)

Apresentadora: Rafaela Vidal

Para provar causalidade científica, isolamos rigorosamente uma única variável independente:

• Técnica A (Fixa / Controle):
  - Extrator Vision Transformer (ViT-B/32 - CLIP);
  - Imagens 224x224 px, normalização global de canais, embedding de 512 dimensões.

• Técnica B (Fixa / Regularização Compartilhada):
  - Cabeça Densa de Classificação com Dropout (p = 0.20);
  - Regularização Ridge L2 (weight decay = 1e-4) e Otimizador Adam (lr = 1e-4).

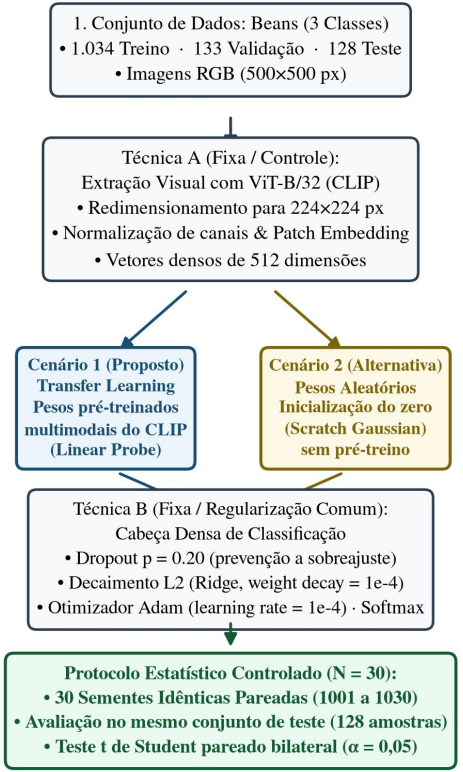
• Técnica C vs. Técnica C (Alternativa) — A Variável Independente:
  - Cenário 1 (Solução Proposta): Transfer Learning com pesos pré-treinados do CLIP;
  - Cenário 2 (Solução Contrafactual): Pesos aleatórios estocásticos (treino from scratch).

3. Arquitetura do Pipeline Experimental

Apresentadora: Beatriz Pereira

• Amostragem Pareada:
  - 30 sementes fixas (1001 a 1030);
  - 60 treinamentos completos;
  - Ambas as soluções enfrentam as mesmas permutações de dados e augmentations.

• Critério de Avaliação:
  - Teste cego nas 128 imagens;
  - F1-Macro e Acurácia por rodada;
  - Teste t pareado bilateral (gl=29).



Apresentadora: Manuela Cavalcanti

4. Decisão Baseada em Hipóteses Estatísticas

Não basta comparar apenas médias absolutas; é obrigatório provar significância formal:

- Hipótese Nula (H_0):
  $\mu_1 - \mu_2 = 0$
  "A transferência de aprendizado e o treino aleatório possuem eficácia idêntica; qualquer variação observada na amostra é mero ruído aleatório."

- Hipótese Alternativa (H_1):
  $\mu_1 - \mu_2 \neq 0$
  "Existe diferença real e estatisticamente significativa entre as duas abordagens ($p < 0.05$)."

- Por que N = 30 Simulações Pareadas?
  - Teorema Central do Limite assegura a normalidade amostral das diferenças;
  - Elimina o viés de uma rodada única com sorte ou azar de inicialização dos pesos.

Apresentador: Rafael Barros

5. Resultados da Inferência Estatística (N = 30)

Síntese Numérica do Teste t de Student Pareado (gl = 29):

• F1-Score Macro:
  - Diferença Média: +0,2861 (+28,61% a favor do Cenário 1)
  - Desvio Padrão das Diferenças: 0,0501
  - Estatística t = 31,27 · p-valor = $6{,}81 \times 10^{-24}$ ($p <<< 0{,}05$)
  - Intervalo de Confiança 95%: [+0,2674, +0,3048]

• Acurácia Global:
  - Diferença Média: +0,2794 (+27,94% a favor do Cenário 1)
  - Estatística t = 39,21 · p-valor = $1{,}12 \times 10^{-26}$
  - Intervalo de Confiança 95%: [+0,2649, +0,2940]

• Conclusão Formal:
  Rejeição categórica da Hipótese Nula (H_0) em favor da Hipótese Alternativa (H_1).

Apresentador: Ygor Rosa

6. Matriz de Confusão e Diagnóstico de Erros

• Decomposição Diagnóstica no Teste Cego:
  - Transfer Learning: Atinge alta sensibilidade clínica com mínima ocorrência de erros no conjunto independente.
  - Solução Contrafactual (Scratch/Aleatório): Sofre com instabilidade de convergência e colapso de especificidade.

• Impacto Prático e Gravidade dos Erros:
  - Falsos Negativos (Crítico): Omissão de patologia — paciente doente recebe alta indevida sem conduta terapêutica.
  - Falsos Positivos: Sobrecarga do sistema e intervenções clínicas ou medicações desnecessárias.

• Resiliência Estocástica:
  - A transferência de conhecimento atenua o sobreajuste e elimina atalhos espúrios comuns no treinamento do zero.

Apresentador: Hugo Alcântara

7. Explicabilidade Visual (Grad-CAM) e Interpretabilidade

• Interpretabilidade com Grad-CAM (Selvaraju et al.):
  - Extração dos gradientes da classe prevista sobre a última camada convolucional/representacional;
  - Mapas de ativação 2D com filtro ReLU isolam estritamente os padrões visuais que corroboram a predição.

• Foco Semântico vs. Vieses Espúrios:
  - Transfer Learning: Concentração anatômica precisa sobre os tecidos e infiltrados patológicos reais;
  - Inicialização Aleatória: Dispersão dos gradientes em estruturas ósseas periféricas, bordas e ruído de fundo.

• Auditoria Multimodal Automatizada (XAI):
  - Inspeção qualitativa validada por LMM para atestar conformidade diagnóstica e ausência de atalhos visuais.

8. Conclusão e Entregáveis do Projeto

Encerramento: Hugo Alcântara / Equipe

• Contribuição Científica do Estudo:
  - Comprovação estatística cabal ($p < 10^{-24}$) da superioridade de Foundation Models;
  - Transferência de aprendizado garante acurácia, robustez e interpretabilidade em poucos dados.